



Conteo de rocas visibles basado en las máscaras de AI4Mars

Juan Pablo Delgado Castro

Programa de Ciencia de Datos

Departamento de Matemáticas

Universidad Externado de Colombia

Modalidad de grado: Informe de investigación

Tutor(es): Juliana De Mier Medellín

Lugar y fecha: Bogotá, Colombia, 2026

Resumen

Las misiones de superficie en Marte han acumulado cientos de miles de imágenes de cámaras de navegación, y el conjunto AI4Mars aporta además máscaras de segmentación por píxel producidas por anotación colaborativa. Esas máscaras se han empleado casi exclusivamente para entrenar redes neuronales, de modo que la información cuantitativa que ya contienen permanece en buena medida sin explotar. Este trabajo pregunta qué indicadores de terreno pueden derivarse directamente de ellas sin entrenar ningún modelo.

Se implementó un procedimiento reproducible de procesamiento clásico de imagen que, para cada máscara, calcula la cobertura de roca visible como cociente entre píxeles de roca y píxeles etiquetados, y estima el número de rocas individuales mediante componentes conectadas, transformada de distancia euclidiana y división de aguas guiada por máximos de prominencia, con filtros explícitos de área y forma. El procedimiento se ejecutó sobre las 16.064 imágenes de la cámara de navegación del rover *Curiosity* que disponen de máscara de entrenamiento.

La cobertura resultó calculable en el 67,3 % de las escenas, con una mediana del 96,8 % sobre píxeles etiquetados, mientras que el conteo se aplicó a 2193 imágenes y arrojó 4204 rocas con una distribución tamaño–frecuencia decreciente. Los dos indicadores resultaron estadísticamente independientes ($r = 0,02$), lo que confirma que miden facetas distintas del terreno. La validación contra las 322 máscaras de experto incluidas en el propio conjunto reveló que la anotación colaborativa sobreestima la cobertura de forma sistemática —la mediana cae al 46,1 %—, sesgo que se atribuye a la mayor saliencia visual de la roca frente al suelo y la arena. Un diagnóstico de los modos de error mostró que el techo del conteo no está en la resolución de las imágenes sino en la taxonomía de las etiquetas: la clase *roca grande* aporta solo el 2,5 % de la roca anotada y es aún más escasa en las máscaras de experto.

El trabajo entrega un conjunto de resultados con veinticuatro indicadores por imagen, un diagnóstico cuantitativo de las limitaciones del conjunto de datos y una comparación con dos en-

foques de aprendizaje automático que sitúa el desempeño del método clásico en contexto. Un contraste adicional del segmentador entrenado frente a las máscaras de experto muestra que, pese a haber aprendido de anotaciones sesgadas, estima la cobertura sin sesgo apreciable, lo que sugiere que el indicador podría calcularse sin anotación humana. Como extensión aplicada, los indicadores se tradujeron en seis reglas de aviso de riesgo de terreno con umbrales explícitos y justificados, y en una aplicación de escritorio que hace los resultados consultables. Se documenta además un resultado negativo: la detección de vetas minerales a partir de la imagen no resulta viable con este material, por razones instrumentales que se precisan.

Palabras clave: Marte; AI4Mars; segmentación semántica; división de aguas; morfología matemática; cobertura de roca; distribución tamaño–frecuencia; anotación colaborativa.

Abstract

Mars surface missions have accumulated hundreds of thousands of navigation-camera images, and the AI4Mars dataset additionally provides pixel-level segmentation masks produced by crowdsourced annotation. These masks have been used almost exclusively to train neural networks, so the quantitative information they already encode remains largely untapped. This work asks which terrain indicators can be derived directly from them without training any model.

A reproducible classical image-processing procedure was implemented. For each mask it computes visible rock coverage as the ratio of rock pixels to labelled pixels, and estimates the number of individual rocks through connected components, the Euclidean distance transform and a watershed guided by prominence maxima, with explicit area and shape filters. The procedure was run over the 16.064 images from the *Curiosity* rover navigation camera that have a training mask available.

Coverage proved computable for 67,3 % of the scenes, with a median of 96,8 % over labelled pixels, while the count applied to 2193 images and yielded 4204 rocks with a decreasing size–frequency distribution. The two indicators turned out to be statistically independent ($r = 0,02$), confirming that they measure distinct facets of the terrain. Validation against the 322 expert masks included in the dataset itself revealed that crowdsourced annotation systematically overestimates coverage —the median drops to 46,1 %— a bias attributed to the greater visual salience of rock compared with soil and sand. An error-mode diagnosis showed that the ceiling on counting lies not in image resolution but in label taxonomy: the *big rock* class contributes only 2,5 % of annotated rock and is even scarcer in the expert masks.

The work delivers a results set with twenty-four per-image indicators, a quantitative diagnosis of the dataset’s limitations, and a comparison against two machine-learning approaches that places the classical method’s performance in context. As an applied An additional test of the trained segmenter against expert masks shows that, despite having learnt from biased annotations, it

estimates coverage without appreciable bias, suggesting the indicator could be computed without human annotation. As an applied extension, the indicators were translated into six terrain-risk alert rules with explicit, justified thresholds, and into a desktop application that makes the results consultable. A negative result is also documented: detecting mineral veins from the imagery is not feasible with this material, for instrumental reasons that are specified.

Keywords: Mars; AI4Mars; semantic segmentation; watershed; mathematical morphology; rock coverage; size–frequency distribution; crowdsourced annotation.

Abreviaturas y siglas

AI4Mars Conjunto de datos abierto de terreno marciano etiquetado por anotación colaborativa, publicado por el Jet Propulsion Laboratory.

APA *American Psychological Association*; estilo de citación empleado en este documento.

CSV *Comma-Separated Values*; formato de archivo tabular en texto plano utilizado para el conjunto de resultados.

EDR *Experiment Data Record*; nivel de procesamiento de los productos de imagen del Planetary Data System.

GEO Taxonomía geológica extendida de AI4Mars, distinta de la escala de navegación y fuera del alcance de este trabajo.

HiRISE *High Resolution Imaging Science Experiment*; cámara orbital del *Mars Reconnaissance Orbiter*.

IoU *Intersection over Union*; índice de solapamiento entre una región predicha y una de referencia.

JPL *Jet Propulsion Laboratory*, NASA.

MAHLI *Mars Hand Lens Imager*; cámara de aproximación del rover *Curiosity*.

MER *Mars Exploration Rovers*; misión de los rovers *Spirit* y *Opportunity*.

MPS *Metal Performance Shaders*; interfaz de aceleración por unidad gráfica en procesadores Apple Silicon.

MSL *Mars Science Laboratory*; misión del rover *Curiosity*.

NAV Escala de clases de navegación de AI4Mars: suelo, lecho rocoso, arena y roca grande.

NavCam *Navigation Camera*; par estéreo de cámaras de navegación en blanco y negro montadas en el mástil del rover.

PDS *Planetary Data System*; archivo público de datos planetarios de la NASA.

SAM *Segment Anything Model*; modelo fundacional de segmentación de propósito general.

Índice general

Resumen	ii
Abstract	iv
Abreviaturas y siglas	vi
Índice de figuras	xii
Índice de tablas	xiv
1. Introducción	1
1.1. Planteamiento del proyecto	1
1.2. Pregunta o propósito central	2
1.3. Justificación y valor esperado	2
1.4. Objetivos	3
1.4.1. Objetivo general	3
1.4.2. Objetivos específicos	4
1.5. Estructura del documento	4
2. Contexto y antecedentes	6
2.1. Caracterización del contexto	6
2.1.1. Las rocas como restricción operativa	6
2.1.2. Cómo se ha medido la roca hasta ahora	6
2.1.3. Segmentación automática de terreno marciano	7
2.1.4. Antecedentes metodológicos: división de aguas	8
2.2. Antecedentes y referentes	9
2.2.1. El conjunto de datos AI4Mars	9
2.2.2. Instrumentación y sus consecuencias	9

2.3. Brecha, necesidad u oportunidad identificada	10
3. Diseño y métodos del proyecto	11
3.1. Enfoque y diseño	11
3.2. Datos y fuentes de información	12
3.2.1. Origen y versión	12
3.2.2. Subconjunto de estudio	12
3.2.3. Codificación de las máscaras	13
3.2.4. Criterios de inclusión	14
3.3. Métodos y herramientas	14
3.3.1. Estructura del procedimiento	14
3.3.2. Cobertura de roca visible (E1)	14
3.3.3. Conteo aproximado de rocas individuales (E2)	15
3.3.4. Parámetros	17
3.3.5. Herramientas y reproducibilidad	17
3.4. Operacionalización de objetivos	19
3.5. Estrategia de evaluación y validación	21
3.6. Consideraciones éticas y de gestión de datos	22
3.7. Cronograma de trabajo	23
4. Resultados y evaluación	27
4.1. Resultados, análisis e interpretación	27
4.1.1. Conjunto analizado	27
4.1.2. Cobertura de roca visible (E1)	28
4.1.3. Conteo aproximado de rocas individuales (E2)	30
4.1.4. Composición del terreno y tipología de escenas (E3)	33
4.1.5. Variación a lo largo del recorrido (E3)	34
4.1.6. Extensión aplicada: de indicador a aviso operativo	35
4.2. Evaluación y validación	40
4.2.1. Contraste con etiquetas de experto	40
4.2.2. Validación con conteo humano	41

4.2.3.	Comparación con métodos de aprendizaje automático	45
4.3.	Implicaciones y limitaciones	49
4.3.1.	Interpretación de los indicadores	49
4.3.2.	El sesgo de la anotación colaborativa	50
4.3.3.	Diagnóstico de los modos de error del conteo	50
4.3.4.	El techo del conteo no está en las imágenes	54
4.3.5.	Una vía para levantar ese techo	54
4.3.6.	Limitaciones restantes	55
5.	Conclusiones y recomendaciones	57
5.1.	Conclusiones	57
5.1.1.	Sobre la pregunta de investigación	57
5.1.2.	Sobre los objetivos específicos	57
5.1.3.	Sobre la independencia de los indicadores	58
5.1.4.	Sobre la calidad de la anotación	58
5.1.5.	Sobre la transmisión del sesgo a un modelo entrenado	59
5.1.6.	Sobre el acuerdo con el juicio humano	60
5.1.7.	Sobre el origen de los errores del conteo	60
5.1.8.	Sobre la detección de vetas	61
5.2.	Aportes	61
5.3.	Recomendaciones	63
5.3.1.	Para el uso de los resultados de este trabajo	63
5.3.2.	Para trabajos futuros sobre AI4Mars	63
5.3.3.	Para quienes evalúan modelos con AI4Mars	64
	Glosario	65
A.	Material complementario	68
A.1.	Esquema del conjunto de resultados	68
A.2.	Casos adicionales del procedimiento	70
A.3.	Modos de error descartados por los filtros	71

A.4. Documentación técnica de la extensión aplicada	72
A.5. Recursos reproducibles	74
Referencias	76

Índice de figuras

3.1. Esquema del procedimiento de cálculo	14
4.1. Procedimiento paso a paso	27
4.2. Composición del conjunto analizado según la bandera de calidad.	28
4.3. Distribución de la cobertura	29
4.4. Cobertura frente a fracción de escena etiquetada.	30
4.5. Distribución del conteo de rocas por imagen.	31
4.6. Distribución tamaño–frecuencia de las rocas contadas.	32
4.7. Tipología de escenas según la composición del terreno.	33
4.8. Variación a lo largo del recorrido	34
4.9. Distribución de los avisos de terreno	37
4.10. Desempeño del detector de vetas	39
4.11. Comparación de la cobertura entre etiquetas colaborativas y de experto.	41
4.12. Acuerdo entre el conteo manual y el automático	43
4.13. Matriz de acuerdo entre el conteo clásico y el modelo general.	45
4.14. Cobertura del modelo frente a la humana	47
4.15. Cobertura del modelo frente a la del experto	48
4.16. Roca visible etiquetada como lecho rocoso	52
4.17. Subdivisión de un afloramiento continuo por la división de aguas.	53
4.18. Artefacto de anotación	53
4.19. Prueba de concepto del enfoque híbrido	55
A.1. Procedimiento sobre una escena con una roca aislada.	70
A.2. Procedimiento sobre una escena con varios bloques próximos.	70

A.3. Procedimiento sobre una escena de terreno mixto.	70
A.4. Procedimiento sobre una escena dominada por afloramiento.	71
A.5. Región por debajo del área mínima	71
A.6. Región descartada por relación de aspecto	72
A.7. Anotación en contorno hueco	72

Índice de tablas

3.1. Codificación de la escala de navegación en las máscaras de AI4Mars v0.6.	13
3.2. Parámetros del procedimiento y su efecto.	17
3.3. Versiones de las bibliotecas utilizadas.	18
3.4. Matriz de operacionalización de objetivos, técnicas e indicadores.	20
3.5. Cronograma de trabajo previsto para quince semanas.	23
4.1. Composición del conjunto según la bandera de calidad.	28
4.2. Distribución del conteo de rocas sobre las imágenes aptas.	30
4.3. Distribución tamaño–frecuencia de las rocas contadas.	32
4.4. Tipología de escenas según la composición del terreno.	33
4.5. Reglas del sistema de aviso	36
4.6. Desempeño del detector de vetas sobre 24 escenas anotadas.	39
4.7. Comparación de indicadores entre máscaras colaborativas y de experto.	40
4.8. Desempeño del segmentador entrenado	46
4.9. Desempeño del modelo según la referencia	48
4.10. Atribución de las escenas con conteo nulo.	51
4.11. Fuentes de conteo excesivo.	52
4.12. Presencia de roca grande según la fuente de etiqueta	54
A.1. Esquema del conjunto de resultados.	69

Capítulo 1

Introducción

1.1. Planteamiento del proyecto

La exploración robótica de Marte ha mostrado que la distribución y el tamaño de las rocas en la superficie no son un detalle accesorio, sino una condición que limita lo que una misión puede hacer. La selección de los sitios de aterrizaje de los *Mars Exploration Rovers* se apoyó explícitamente en distribuciones tamaño–frecuencia de rocas derivadas de imágenes orbitales [9], y el mismo tipo de análisis se repitió para el *Mars Science Laboratory* [10] y para el módulo *InSight* [8]. La razón es práctica: una roca de tamaño suficiente puede impedir el despliegue de un instrumento, obligar a un desvío costoso o dañar el vehículo. El desgaste prematuro de las ruedas de *Curiosity* sobre terreno de lecho rocoso con aristas agudas quedó documentado como lección aprendida de la propia misión [19].

Las misiones de superficie han acumulado, a lo largo de dos décadas, cientos de miles de imágenes tomadas desde el propio terreno. Sobre ese acervo, el conjunto de datos AI4Mars [25, 24] añadió algo poco frecuente: máscaras de segmentación por píxel para decenas de miles de escenas, producidas mediante anotación colaborativa y depuradas exigiendo acuerdo entre anotadores. Cada píxel de esas máscaras lleva una etiqueta de tipo de terreno.

El uso que ha recibido ese material es, casi sin excepción, el de insumo para entrenar redes neuronales de segmentación. Una revisión sistemática reciente de las técnicas de segmentación de imágenes marcianas entre 2019 y 2025 [20] recoge una sucesión de arquitecturas —redes convolucionales, transformadores, variantes ligeras para cómputo a bordo— evaluadas todas ellas por su

capacidad de reproducir las máscaras. La máscara funciona como la respuesta correcta contra la cual se mide un modelo.

Este trabajo parte de una observación distinta. Las máscaras de AI4Mars no son solo la respuesta de un problema de aprendizaje: son en sí mismas un mapa cuantitativo del terreno. Si un píxel etiquetado como roca informa de que en ese punto de la escena hay roca, entonces contar píxeles y agrupar los que se tocan permite medir cuánta roca hay y cómo está organizada, sin entrenar ningún modelo y sin generar máscaras nuevas. Esa información ya está pagada —el esfuerzo de anotación ya se realizó— y permanece en buena medida sin explotar.

1.2. Pregunta o propósito central

La pregunta que orienta el trabajo es la siguiente:

¿Cómo cuantificar, a partir de las máscaras etiquetadas de AI4Mars, la cobertura de roca visible y el número aproximado de rocas individuales por imagen, mediante un flujo de procesamiento de imágenes con parámetros explícitos y resultados reproducibles?

La pregunta tiene dos mitades de dificultad muy distinta. Medir cobertura es, en esencia, un conteo de píxeles con un denominador bien elegido. Contar rocas individuales exige resolver un problema de segmentación de instancias sobre una máscara que no distingue instancias: cuando dos rocas se tocan, la máscara las registra como una sola región conectada, y separarlas requiere criterios geométricos. El trabajo aborda las dos y reporta con igual detalle dónde cada una funciona y dónde no.

1.3. Justificación y valor esperado

El interés de derivar indicadores directamente de las máscaras es triple.

En primer lugar, **transparencia**. Un indicador calculado con morfología matemática y división de aguas se puede auditar: cada umbral es un número explícito y cada etapa intermedia es una imagen que puede inspeccionarse. Un modelo entrenado entrega una predicción cuya justificación

no es directamente legible. Para un uso en el que el resultado deba defenderse ante un tercero —la planificación de una travesía, por ejemplo— esa diferencia importa.

En segundo lugar, **costo**. El procedimiento propuesto corre sobre procesador convencional, sin unidad gráfica ni conjunto de entrenamiento, y procesa el subconjunto completo en minutos. Esto lo hace reproducible en cualquier equipo y adecuado como línea de base contra la cual comparar métodos más costosos.

En tercer lugar, y de manera menos evidente, **diagnóstico del propio conjunto de datos**. Al derivar medidas cuantitativas de las máscaras y contrastarlas con las máscaras de experto que AI4Mars incluye para validación, el procedimiento se convierte en un instrumento para examinar la calidad de la anotación. El trabajo encontró en esa dirección uno de sus resultados más relevantes, expuesto en el Capítulo 4: la anotación colaborativa sobreestima de forma sistemática la cobertura de roca. Ese hallazgo tiene consecuencias para cualquier estudio que use AI4Mars, incluidos los que entrenan modelos.

El valor esperado del trabajo es, por tanto, un procedimiento documentado, un conjunto de resultados reutilizable con un indicador por imagen y un diagnóstico honesto de los límites que impone el material de partida.

1.4. Objetivos

1.4.1. Objetivo general

Diseñar, implementar y documentar un procedimiento de procesamiento de imágenes que, a partir de las máscaras etiquetadas del conjunto de datos AI4Mars, permita cuantificar para cada imagen la proporción de terreno ocupada por roca visible y el número aproximado de rocas individuales presentes en las zonas etiquetadas como roca grande, de forma que los resultados sean reproducibles y comparables entre diferentes escenas.

1.4.2. Objetivos específicos

- E1.** Estimar, para cada imagen con máscara válida de AI4Mars, la cobertura de roca visible, entendida como el porcentaje de píxeles etiquetados de la escena que corresponden a roca expuesta o roca grande.
- E2.** Estimar, para cada imagen, el número aproximado de rocas individuales presentes en las zonas etiquetadas como roca grande, separando las que aparecen pegadas en la máscara mediante componentes conectadas, transformada de distancia y división de aguas, y filtrando las regiones resultantes según criterios de tamaño y forma.
- E3.** Explorar de forma descriptiva cómo cambian la cobertura y el conteo entre distintos subconjuntos y a lo largo del recorrido del rover, en la medida en que esa información esté presente en los metadatos disponibles.
- E4.** Implementar el procedimiento en un conjunto de recursos reproducibles que incluya código, guiones de ejecución, parámetros empleados, versiones de biblioteca y un archivo tabular con los indicadores calculados para cada imagen.
- E5.** Analizar e interpretar los indicadores obtenidos, identificando patrones generales, casos atípicos y limitaciones del procedimiento, y plantear líneas de trabajo futuras que puedan construirse sobre estos resultados.

1.5. Estructura del documento

El Capítulo 2 caracteriza el contexto del problema, revisa los antecedentes en abundancia de rocas y en segmentación de terreno marciano, y precisa la brecha que el trabajo aborda. El Capítulo 3 describe el diseño del estudio, la fuente de datos, el procedimiento de cálculo con todos sus parámetros y la estrategia de validación. El Capítulo 4 presenta los resultados de los cinco objetivos específicos, su validación contra etiquetas de experto y una comparación con dos enfoques de aprendizaje automático, y discute las implicaciones y limitaciones, incluido un diagnóstico cuanti-

tativo del origen de los errores del conteo. El Capítulo 5 sintetiza las conclusiones, los aportes y las recomendaciones. El Anexo A recoge material de soporte: el esquema del conjunto de resultados, casos adicionales del procedimiento y la descripción de los recursos reproducibles.

Capítulo 2

Contexto y antecedentes

2.1. Caracterización del contexto

2.1.1. Las rocas como restricción operativa

Un rover en Marte no dispone de asistencia. Cada metro recorrido se planifica desde la Tierra sobre imágenes tomadas el sol anterior, y cualquier obstáculo que el equipo de navegación no advierta se convierte en un riesgo real. Las rocas concentran ese riesgo por tres vías distintas.

La primera es el daño mecánico. Las ruedas de aluminio de *Curiosity* sufrieron perforaciones y desgarros muy por encima de lo previsto al transitar sobre lecho rocoso con aristas agudas fijas al sustrato, hasta el punto de motivar un cambio en la estrategia de conducción y una lección aprendida formal de la misión [19]. A diferencia de un bloque suelto, que cede al ser pisado, la roca anclada transmite toda la carga a la rueda.

La segunda es el bloqueo de trayectoria. Un bloque de tamaño suficiente obliga a rodearlo, y en terreno con muchos bloques los desvíos se acumulan hasta hacer inviable una ruta.

La tercera es el riesgo en el descenso. La abundancia de rocas por encima de un umbral de tamaño determina la probabilidad de que un módulo se apoye sobre un obstáculo o vuelque, y por eso entra directamente en la selección de sitio [16].

2.1.2. Cómo se ha medido la roca hasta ahora

La caracterización cuantitativa de rocas en superficies planetarias tiene una tradición consolidada, y su instrumento central es la **distribución tamaño–frecuencia**: el número de rocas por unidad de área que supera cada tamaño. Golombek y col. [9] establecieron el procedimiento para

los sitios de los *Mars Exploration Rovers*, midiendo rocas sobre imágenes orbitales de alta resolución y ajustando modelos exponenciales; el mismo esquema se aplicó al sitio del *Mars Science Laboratory* [10] y, con instrumentación distinta, al entorno de *InSight* [8].

El enfoque se ha trasladado a otras misiones y otros cuerpos. En el sitio del rover chino *Zhurong*, en *Utopia Planitia*, la abundancia de rocas y la tasa de erosión se estimaron a partir de imágenes de superficie [4, 23]. En la Luna, Di y col. [6] midieron la distribución en el entorno del módulo *Chang’e-3*, y Watkins y col. [31] estudiaron la distribución de bloques alrededor de cráteres de impacto jóvenes.

Estos trabajos comparten dos rasgos que conviene subrayar. Producen medidas **métricas** — tamaños en centímetros o metros, densidades por metro cuadrado—, lo que exige conocer la escala de la imagen mediante geometría de la cámara o estereoscopia. Y la identificación de las rocas es en buena parte **manual o semiautomática**: un especialista delimita los bloques sobre la imagen.

2.1.3. Segmentación automática de terreno marciano

En paralelo se ha desarrollado una línea de trabajo que busca automatizar la interpretación del terreno mediante aprendizaje profundo. La revisión sistemática de Qu y col. [20] documenta la evolución del campo entre 2019 y 2025.

El trabajo de referencia en clasificación de terreno para planificación de travesías es el sistema SPOC del Jet Propulsion Laboratory [21], que clasifica tipos de suelo y objetos en imágenes de rover para apoyar la selección de rutas. Sobre esa base, y una vez disponible AI4Mars, apareció una sucesión de arquitecturas cada vez más especializadas: redes ligeras pensadas para cómputo a bordo como SegMarsViT [5] y variantes bilaterales; redes de atención híbrida para terreno no estructurado [15]; transformadores como MarsFormer [32] y modelos que incorporan información de profundidad [17]; y variantes de U-Net con atención orientadas específicamente a roca [26]. Se han propuesto además conjuntos de datos complementarios, basados en textura [30] o en segmentación por características de textura sin aprendizaje profundo [1].

El rasgo común de toda esta línea es su criterio de éxito: la métrica reportada es siempre el acuerdo con la máscara de referencia, medido con índices como la intersección sobre la unión. El objetivo es *reproducir la anotación humana*.

2.1.4. Antecedentes metodológicos: división de aguas

El procedimiento de conteo empleado en este trabajo se apoya en una técnica clásica de morfología matemática. La formulación eficiente de la división de aguas por simulación de inmersión se debe a Vincent y Soille [27]: la imagen se interpreta como un relieve topográfico que se inunda progresivamente desde sus mínimos, y las fronteras entre cuencas de inundación definen la segmentación.

Aplicada a una imagen binaria, la técnica requiere un paso previo. Se calcula la transformada de distancia euclidiana, que asigna a cada píxel activo su distancia al fondo más cercano; sobre esa superficie, los centros de las regiones aparecen como máximos locales y los estrechamientos entre objetos pegados como valles. Inundando el negativo de esa superficie desde los máximos se obtiene una partición que corta precisamente por los estrechamientos, que es donde dos rocas en contacto se separarían a ojo.

Este esquema es de uso corriente en dominios donde hay que contar objetos que se tocan. En minería y geotecnia se aplica a la estimación de la distribución de tamaños de fragmentos de roca tras una voladura, tanto con métodos clásicos como con redes convolucionales [12, 22]. En cartografía de riesgo por caída de rocas se emplea sobre inventarios obtenidos por teledetección [11]. La implementación utilizada aquí es la de la biblioteca `scikit-image` [29], sobre las estructuras de NumPy [13] y SciPy [28].

2.2. Antecedentes y referentes

2.2.1. El conjunto de datos AI4Mars

AI4Mars [25] reúne imágenes de los rovers *Spirit*, *Opportunity* y *Curiosity*, procedentes del Planetary Data System [18], con máscaras de segmentación por píxel obtenidas mediante anotación colaborativa. Miles de voluntarios marcaron el tipo de terreno y las anotaciones se consolidaron exigiendo acuerdo de al menos dos de cada tres anotadores; los píxeles sin consenso quedaron sin etiqueta. La versión empleada en este trabajo es la 0.6 [24].

La escala de navegación distingue cuatro clases —suelo, lecho rocoso, arena y roca grande— más un valor reservado para el píxel sin etiqueta. Esa distinción entre lecho rocoso y roca grande es central para este trabajo y merece precisarse: el lecho rocoso designa roca expuesta en continuidad con el sustrato, mientras que la roca grande designa bloques discretos. Es una distinción geológicamente sensata, pero, como se verá, su aplicación práctica por parte de anotadores no especialistas resulta difícil de sostener de manera consistente.

El conjunto incluye, además de las máscaras colaborativas de entrenamiento, un subconjunto de máscaras anotadas por especialistas con distintos niveles de exigencia de acuerdo, destinado a validación. Esa inclusión resultó decisiva para este trabajo, porque permitió contrastar los indicadores contra una referencia de mayor calidad sin necesidad de producir anotación propia.

2.2.2. Instrumentación y sus consecuencias

Las imágenes empleadas provienen de la cámara de navegación de *Curiosity*, un par estéreo montado en el mástil que produce imágenes de un megapíxel en escala de grises. Es una cámara de ingeniería: su función es la conducción, no la caracterización mineralógica. Los instrumentos con los que se caracteriza composición y textura fina en la misión son otros —la cámara de mástil multispectral [2] y la lupa de mano [7]—, y esa diferencia acota lo que cabe esperar de un análisis basado en imágenes de navegación.

2.3. Brecha, necesidad u oportunidad identificada

De la revisión anterior se desprenden dos vacíos complementarios.

Los estudios de abundancia de rocas producen medidas métricas rigurosas, pero a costa de identificación manual o semiautomática y sobre muestras reducidas: unas pocas escenas cuidadosamente analizadas por sitio de aterrizaje. No escalan a decenas de miles de imágenes.

Los trabajos de segmentación automática sí escalan, pero su objetivo es reproducir la máscara. Producen un modelo, no un indicador. Una vez que la máscara existe —y en AI4Mars existe para más de dieciséis mil escenas de la cámara de navegación de *Curiosity*— nadie ha planteado sistemáticamente la pregunta inversa: qué se puede medir directamente sobre ella.

La oportunidad es precisamente ese hueco. Las máscaras de AI4Mars constituyen un mapa cuantitativo del terreno ya construido y validado, y sobre él pueden derivarse indicadores interpretables con técnicas clásicas, transparentes y de bajo costo computacional. Hacerlo tiene además un beneficio de segundo orden: al comparar los indicadores derivados de las máscaras colaborativas con los derivados de las máscaras de experto que el propio conjunto incluye, el procedimiento se convierte en un instrumento de diagnóstico de la calidad de la anotación, con implicaciones para todos los trabajos que la utilizan como referencia.

Este trabajo se sitúa en ese hueco. No propone una arquitectura nueva ni compite con los modelos de segmentación; toma la máscara como dato de entrada y pregunta qué información cuantitativa puede extraerse de ella de forma reproducible, y con qué límites.

Capítulo 3

Diseño y métodos del proyecto

3.1. Enfoque y diseño

El estudio adopta un **enfoque metodológico cuantitativo**: todo el conocimiento que produce proviene de medidas numéricas derivadas de las máscaras, y las afirmaciones se sostienen en estadísticos calculados sobre ellas y no en interpretación de material cualitativo. Dentro de los tipos de investigación, corresponde a una investigación **descriptiva con componente aplicado**: descriptiva porque su propósito es caracterizar el terreno mediante indicadores y no explicar relaciones causales ni predecir; y con componente aplicado porque los indicadores se construyen para un uso concreto —la caracterización de escenas con fines de transitabilidad— y no como ejercicio teórico.

Desde el punto de vista del diseño, el estudio es **observacional, descriptivo y de corte transversal**. Observacional porque no se interviene sobre el objeto de estudio: se analizan máscaras ya producidas, sin generar anotación nueva ni modificar las imágenes. Descriptivo porque el propósito es caracterizar el terreno mediante indicadores cuantitativos, no contrastar hipótesis causales. Y de corte transversal porque cada imagen se analiza de forma independiente, como una observación aislada; el orden de adquisición se emplea únicamente como variable descriptiva y no como serie temporal calibrada.

La **unidad de análisis** es la pareja formada por una imagen y su máscara de segmentación. Cada unidad produce una fila del conjunto de resultados con los indicadores calculados. No hay agregación previa: las estadísticas del Capítulo 4 se derivan de esas filas.

Una decisión de diseño conviene explicitarla desde el principio, porque condiciona la interpretación de todo lo que sigue: **el procedimiento no lee las imágenes**. Toda la información que

consume proviene de la máscara. Las imágenes se emplean únicamente para la inspección visual de las figuras y para fijar el identificador de cada escena. Esta elección responde a la pregunta de investigación —qué puede medirse sobre las máscaras— pero impone un techo que el Capítulo 4 cuantifica.

3.2. Datos y fuentes de información

3.2.1. Origen y versión

Las fuentes de información de este trabajo son **exclusivamente secundarias**: no se recoge dato primario alguno. Ni se toman imágenes nuevas —proviene de una misión espacial— ni se produce anotación propia: las máscaras las generaron terceros. La técnica de recolección es, en consecuencia, **la revisión y el procesamiento de un conjunto de datos documental preexistente**, seleccionado según los criterios que se detallan más adelante.

Se emplea el conjunto AI4Mars en su versión 0.6 [24], descargada del repositorio público. El conjunto reúne imágenes de los rovers *Spirit*, *Opportunity* y *Curiosity* procedentes del Planetary Data System [18], junto con máscaras de segmentación por píxel obtenidas por anotación colaborativa.

3.2.2. Subconjunto de estudio

El alcance se restringe a la **cámara de navegación del rover *Curiosity* con máscaras colaborativas de entrenamiento**. Quedan fuera los rovers de la misión *Mars Exploration Rovers*, el rover *Perseverance* y la cámara de mástil multiespectral. La restricción persigue homogeneidad instrumental: todas las escenas provienen del mismo sensor, con la misma resolución y el mismo régimen radiométrico, de modo que las comparaciones entre imágenes no arrastran diferencias de cámara.

El emparejamiento entre imagen y máscara se realiza por coincidencia del nombre base. El directorio de imágenes contiene 18.127 archivos y el de máscaras de entrenamiento 16.064; el análisis se aplica a las 16.064 parejas completas, ya que sin máscara no hay dato de entrada.

3.2.3. Codificación de las máscaras

Cada máscara es una imagen en escala de grises del mismo tamaño que la original — 1024×1024 píxeles— donde el valor entero de cada píxel identifica la clase de terreno. La Tabla 3.1 recoge la codificación de la escala de navegación.

Tabla 3.1: Codificación de la escala de navegación en las máscaras de AI4Mars v0.6.

Valor	Clase	Descripción
0	Suelo (<i>soil</i>)	Regolito compacto transitable.
1	Lecho rocoso (<i>bedrock</i>)	Roca expuesta en continuidad con el sustrato.
2	Arena (<i>sand</i>)	Depósito suelto, riesgo de atrapamiento.
3	Roca grande (<i>big rock</i>)	Bloque discreto apoyado sobre el terreno.
255	Sin etiqueta (<i>null</i>)	Píxel sin clase asignada.

Esta codificación se verificó de tres formas independientes antes de calcular ningún indicador: contra el archivo de claves de clase distribuido con el conjunto, contra su documentación, y píxel a píxel sobre una muestra de máscaras contrastada con las imágenes correspondientes. La verificación fue necesaria porque la codificación asumida en la fase de propuesta era incorrecta —suponía cinco clases con el fondo en el valor cero— y haberla arrastrado habría invalidado silenciosamente todos los resultados.

El valor 255 agrupa dos situaciones distintas: píxeles sin acuerdo suficiente entre anotadores y píxeles que el propio conjunto excluye por diseño, correspondientes al cuerpo del rover, al cielo y a distancias superiores a treinta metros. En ambos casos el píxel se excluye de todos los cálculos, y la fracción que representa se reporta como indicador de calidad de cada escena.

3.2.4. Criterios de inclusión

Se calcula la cobertura para toda máscara con al menos un píxel etiquetado. El conteo de rocas se aplica únicamente a las máscaras que contienen al menos un píxel de la clase roca grande, ya que es la única sobre la que el indicador está definido. Ninguna imagen se descarta del conjunto de resultados: las que no admiten un indicador reciben una bandera de calidad que lo documenta, de modo que el conjunto final describe también sus propias ausencias.

3.3. Métodos y herramientas

3.3.1. Estructura del procedimiento

La Figura 3.1 resume el flujo completo. La máscara de entrada se bifurca en dos ramas: una calcula la cobertura por conteo de píxeles, y la otra estima el número de rocas mediante una secuencia de operaciones geométricas.




Figura 3.1: Esquema del procedimiento. La rama superior calcula la cobertura de roca visible (E1) por conteo de píxeles; la inferior estima el número de rocas individuales (E2) mediante morfología matemática y división de aguas.

3.3.2. Cobertura de roca visible (E1)

Sea M la máscara y $|\cdot|$ el cardinal de un conjunto de píxeles. Se definen el conjunto de píxeles válidos y el de píxeles de roca como

$$V = \{p : M(p) \neq 255\}, \quad R = \{p : M(p) \in \{1, 3\}\},$$

es decir, la roca agrupa el lecho rocoso y la roca grande. La cobertura se define como

$$C = 100 \cdot \frac{|R|}{|V|}. \quad (3.1)$$

La elección del denominador merece justificación, porque no es neutral. Usar $|V|$ responde a la pregunta *qué fracción del terreno clasificado es roca*, que es la definición adoptada en la propuesta. La alternativa —dividir por el total de píxeles de la imagen— responde a una pregunta distinta y entrega una cota inferior conservadora, ya que trata los píxeles sin etiqueta como si no fueran roca. Ambas medidas se reportan en el conjunto de resultados, junto con la fracción de escena etiquetada $|V|/|M|$, que permite al lector juzgar cuánto pesa la diferencia en cada escena.

El riesgo de esta elección es que una escena escasamente etiquetada produzca coberturas altas espurias. El Capítulo 4 contrasta explícitamente esa hipótesis.

3.3.3. Conteo aproximado de rocas individuales (E2)

El conteo opera sobre la máscara binaria $B = \{p : M(p) = 3\}$ y consta de seis etapas.

Limpieza morfológica. Se aplica una apertura seguida de un cierre, ambos con elemento estructurante de 3×3 píxeles. La apertura elimina píxeles aislados producto de imprecisiones en el trazado de los polígonos de anotación; el cierre rellena huecos pequeños dentro de una misma región.

Componentes conectadas. Se etiquetan las regiones conectadas con criterio de ocho vecinos. Su número se registra como indicador independiente, porque comparado con el conteo final permite medir cuánta subdivisión introduce la división de aguas.

Transformada de distancia. Sobre la binaria limpia se calcula la transformada de distancia euclidiana: cada píxel de roca recibe su distancia al fondo más cercano. La superficie resultante se suaviza con un filtro gaussiano de desviación $\sigma = 3,0$ píxeles, con el fin de evitar que las irregularidades del contorno generen máximos espurios.

Detección de semillas por prominencia. Las semillas de la división de aguas se obtienen mediante la **transformada de máximos h** , que conserva únicamente los máximos cuya altura sobre el entorno supera un umbral $h = 1,0$ píxeles de distancia.

Este punto concentra la principal decisión de calibración del trabajo y conviene explicarlo. La alternativa habitual es detectar máximos locales imponiendo una separación mínima entre ellos. Ese criterio falla en un caso concreto y frecuente: una losa de lecho rocoso extensa etiquetada como roca grande genera, sobre la transformada de distancia suavizada, una cresta larga con muchas ondulaciones de poca altura, cada una de las cuales se convierte en una semilla y por tanto en una roca. Se observaron casos en que una sola región continua producía hasta ciento cuarenta y dos semillas. El criterio de prominencia descarta esas ondulaciones porque su altura sobre el entorno es pequeña, y conserva los máximos que corresponden a centros genuinos de bloques.

Se verificó que el criterio actúa de forma **selectiva**, lo cual era la propiedad deseada y no algo garantizado de antemano: sobre escenas marcadas como sospechosas —solidez media inferior a 0,7 o más de quince rocas— reduce el conteo entre un 32 % y un 44 %, mientras que en escenas normales, de una a cinco rocas y regiones compactas, no altera ningún conteo.

División de aguas. Se inunda el negativo de la transformada de distancia partiendo de las semillas, restringiendo el crecimiento a la máscara binaria [27]. El resultado es una partición de la región de roca grande en subregiones disjuntas.

Filtrado por tamaño y forma. Cada subregión debe superar dos criterios para contarse como roca: un **área mínima** del 0,05 % del área de la imagen —524 píxeles para una imagen de 1024×1024 —, y una **relación de aspecto** de su caja envolvente no superior a 5,0. El primero descarta motas de anotación; el segundo descarta bandas muy alargadas, que en la práctica corresponden a trazados manuales del horizonte y no a bloques.

3.3.4. Parámetros

Todos los umbrales se pasan como argumentos con valores por defecto documentados; ninguno está fijado dentro de la lógica de cálculo. La Tabla 3.2 los recoge.

Tabla 3.2: Parámetros del procedimiento y su efecto.

Parámetro	Valor	Efecto
Apertura	3	Elimina motas de anotación.
Cierre	3	Rellena huecos internos.
Área mínima	0,05 %	Descarta regiones demasiado pequeñas.
Relación de aspecto	5,0	Descarta bandas alargadas.
Suavizado σ	3,0	Evita máximos espurios del contorno.
Prominencia h	1,0	Suprime la subdivisión de regiones continuas.
Conectividad	8	Admite contacto diagonal entre píxeles.

La calibración se realizó por inspección visual sobre escenas de tipos de terreno distintos, comparando el resultado de la división de aguas con la imagen original, según el criterio de que un parámetro está bien ajustado cuando el corte reproduce la separación que un observador humano trazaría.

3.3.5. Herramientas y reproducibilidad

El procedimiento se implementó en Python sobre NumPy [13], SciPy [28] y scikit-image [29], con pandas para la construcción del conjunto de resultados. Corre íntegramente en procesador convencional y no requiere unidad gráfica. La Tabla 3.3 registra las versiones empleadas.

Tabla 3.3: Versiones de las bibliotecas utilizadas.

Componente	Versión
Python	3.13.13
NumPy	2.5.1
SciPy	1.18.0
scikit-image	0.26.0
pandas	3.0.5
Pillow	12.3.0

El código se organiza en módulos de responsabilidad única, con funciones que reciben arreglos y devuelven arreglos o números, sin efectos secundarios. Una única función concentra la lógica de segmentación y es reutilizada tanto por el cálculo de indicadores como por la generación de figuras, de modo que las figuras ilustran necesariamente el mismo cálculo que produce los resultados. El Anexo A describe la organización de los recursos.

La reproducibilidad se sostiene además en **control de versiones**. Todo el material —código, guiones de ejecución, conjunto de resultados, figuras y la fuente de este documento— se mantiene en un repositorio Git de historial público, de modo que cada resultado puede rastrearse hasta el estado exacto del código que lo produjo. El conjunto de datos no se versiona, por su volumen: el código lo referencia mediante una variable de entorno configurable, y se descarga de la fuente original. Los parámetros no se fijan dentro de la lógica de cálculo sino que se pasan como argumentos con valores por defecto documentados, de manera que una reejecución con los mismos parámetros entrega necesariamente los mismos resultados; el procedimiento es determinista y no interviene ninguna fuente de aleatoriedad.

3.4. Operacionalización de objetivos

El Cuadro 3.4 recoge la matriz de operacionalización, que hace explícita la correspondencia entre cada objetivo específico, la pregunta que responde, la técnica empleada, la fuente de información, el resultado esperado y el indicador con que se verifica. Su función es garantizar la trazabilidad del diseño: ninguna conclusión del Capítulo 4 carece de un objetivo, una técnica y una métrica asociados.

Tabla 3.4: Matriz de operacionalización de objetivos, técnicas e indicadores.

Objetivo	Pregunta	Técnica	Fuente	Resultado esperado	Indicador / métrica
E1. Estimar la cobertura de roca visible	¿Qué proporción del terreno clasificado de una escena es roca?	Conteo de píxeles por clase sobre los píxeles etiquetados	AI4Mars, máscaras MSL NavCam <i>train</i> (secundaria)	Indicador de cobertura para toda escena con algún píxel etiquetado	rock_coverage_pct y coverage_total_pct; control del artefacto del denominador mediante correlación con frac_valid
E2. Estimar el número de rocas individuales	¿Cuántos bloques discretos se distinguen en las zonas etiquetadas como roca grande?	Morfología matemática, componentes conectadas, transformada de distancia y división de aguas con máximos de prominencia	Ídem, clase <i>roca grande</i>	Conteo por imagen y distribución tamaño-frecuencia	n_rocks, n_raw_components, mean_solidity; acuerdo con conteo humano (kappa de Cohen simple y ponderado)
E3. Explorar la variación entre subconjuntos	¿Cómo cambian los indicadores según la composición del terreno y a lo largo del recorrido?	Estadística descriptiva, tipología de escenas por clase dominante, agregación por tramos del reloj de nave	Conjunto de resultados propio y metadatos del identificador de imagen	Caracterización del terreno y perfil del recorrido	dominant_class, scene_type, proporción de escenas con roca grande por tramo; correlación entre los dos indicadores
E4. Implementar recursos reproducibles	¿Puede otra persona repetir el análisis y obtener los mismos resultados?	Modularización con parámetros explícitos, control de versiones, registro de versiones de biblioteca	Código propio	Archivo tabular con un indicador por imagen, más código y guiones de ejecución	16.064 filas × 24 columnas en results.csv; ejecución determinista con parámetros documentados
E5. Analizar, interpretar y delimitar	¿Qué patrones, casos atípicos y limitaciones presentan los indicadores obtenidos?	Contraste con máscaras de experto, validación con conteo humano, diagnóstico de modos de error y comparación con aprendizaje automático	Máscaras de experto del propio conjunto (322); conteo humano propio (60 escenas)	Cuantificación del sesgo de la anotación y atribución de los límites del conteo	Diferencia de cobertura entre fuentes de etiqueta; kappa del conteo; IoU del segmentador frente a ambas referencias

Dos lecturas de esta matriz conviene anticipar. La primera es que los indicadores de E1 y E2 se verifican con métricas de naturaleza distinta: la cobertura mediante un control interno de consistencia —no existe verdad de campo con la que compararla— y el conteo mediante acuerdo con un observador humano. La segunda es que E5 no produce un indicador propio sino que **mide la confianza atribuible** a los indicadores anteriores, y de ahí que sus métricas sean comparaciones entre fuentes y no medidas de terreno.

3.5. Estrategia de evaluación y validación

Un procedimiento descriptivo como este no admite una métrica de acierto única, porque no existe verdad de campo sobre el número de rocas de una escena. La validación se abordó por tanto en cinco frentes complementarios.

Verificación de la codificación. Comprobación triple de la correspondencia entre valores y clases, descrita más arriba. Es la validación más elemental y la más crítica, porque un error en este punto no produce fallos visibles.

Control del artefacto del denominador. Contraste explícito entre la cobertura y la fracción de escena etiquetada, para descartar que las coberturas altas sean un efecto de la fórmula de la ecuación (3.1) y no del terreno.

Contraste con etiquetas de experto. El conjunto incluye 322 máscaras anotadas por especialistas con acuerdo del 100 %, en tres niveles de exigencia según el número mínimo de anotadores coincidentes. Se ejecutó sobre ellas el mismo procedimiento, **sin modificar ningún parámetro**, y se compararon los indicadores resultantes con los obtenidos de las máscaras colaborativas. Este contraste no mide el acierto del procedimiento sino la calidad del dato de entrada, y resultó ser la fuente del hallazgo más relevante del trabajo.

Contraste con conteo humano. Sobre una muestra de 60 escenas con roca grande se recogió un conteo manual por bandas —cero, una a tres, cuatro a nueve, diez a veinticuatro, veinticinco a cuarenta y nueve, cincuenta o más— y se comparó con el automático mediante el coeficiente kappa de Cohen, en su versión simple y ponderada, esta última apropiada porque las bandas son ordinales. El material se presentó con identificadores neutros y en orden barajado, resaltando en cada imagen la región etiquetada como roca grande, de modo que persona y procedimiento respondieran a la misma pregunta: cuántas rocas se distinguen **dentro de esa región**. Preguntar por la escena completa habría mezclado dos cuestiones distintas —si la anotación es completa y si el procedimiento la subdivide bien—. El resultado automático no apareció en el material consultado al responder. Una ronda piloto previa, de 24 escenas y cuatro bandas, sirvió para detectar y corregir defectos del instrumento antes de recoger los datos definitivos; la subsección 4.2.2 los detalla.

Comparación con aprendizaje automático. Como referencia externa se contrastó el procedimiento con dos enfoques de aprendizaje profundo ejecutados en equipo local: un modelo fundacional de segmentación aplicado sin entrenamiento específico [14, 33] y un segmentador entrenado por aprendizaje por transferencia sobre las propias máscaras [3]. El propósito no es competir con ellos, sino situar el desempeño del método clásico y separar las limitaciones atribuibles al procedimiento de las atribuibles a los datos.

A estos frentes se añadió, tras observar comportamientos anómalos en el conteo, un **diagnóstico sistemático de los modos de error**, que atribuye cada tipo de fallo a su causa —la etiqueta, los umbrales o el algoritmo— y se reporta en el Capítulo 4.

3.6. Consideraciones éticas y de gestión de datos

El trabajo no involucra sujetos humanos ni datos personales, de modo que no requiere aprobación de un comité de ética. Hay, sin embargo, tres consideraciones pertinentes.

Procedencia y licencia. Las imágenes son productos públicos de la NASA obtenidos del Planetary Data System [18], y las máscaras se distribuyen con el conjunto AI4Mars [24] bajo licencia

abierta. Ambas fuentes se citan explícitamente. El conjunto de datos, de unos dieciséis gigabytes, no se redistribuye con el material del proyecto: el código lo referencia por una ruta configurable, de modo que cualquier persona lo descargue de la fuente original.

Reconocimiento del trabajo de anotación. Las máscaras existen gracias al esfuerzo de miles de voluntarios. Un trabajo que analiza críticamente la calidad de esa anotación —como hace este— tiene la obligación de precisar el alcance de su crítica: el sesgo que se documenta en el Capítulo 4 es un efecto estructural del diseño de la tarea de anotación, no una deficiencia atribuible a quienes la realizaron.

Alcance de las afirmaciones. Los indicadores derivados son relativos al conjunto de máscaras del que provienen y no constituyen estimaciones absolutas de la abundancia de roca en el terreno marciano. Presentarlos como tales sería una sobreinterpretación del dato, y el documento evita hacerlo de forma explícita en cada resultado afectado.

3.7. Cronograma de trabajo

El trabajo se planificó sobre quince semanas académicas. El Cuadro 3.5 resume las actividades previstas por semana.

Tabla 3.5: Cronograma de trabajo previsto para quince semanas.

Sem.	Actividades previstas
1	Revisión inicial de la literatura sobre conteo de objetos en imágenes, segmentación semántica y métodos de división de aguas. Familiarización con la documentación de AI4Mars y con el contexto de operación del rover.
2	Instalación y prueba del entorno de trabajo: Python, bibliotecas de procesamiento de imágenes y control de versiones. Descarga de un subconjunto pequeño para pruebas rápidas y comprensión del formato.

Sem. Actividades previstas

- 3 Selección del conjunto de imágenes y máscaras definitivo. Organización de los directorios de datos y primeros guiones para leer y visualizar las máscaras de forma consistente.
 - 4 Construcción de las dos máscaras binarias de trabajo: una para la cobertura —lecho rocoso y roca grande— y otra solo para roca grande. Cálculo preliminar de la cobertura por imagen, para verificar que los valores sean razonables.
 - 5 Implementación del módulo de componentes conectadas sobre la máscara de roca grande. Cálculo de área y forma de cada componente y diseño de los filtros iniciales.
 - 6 Primeros experimentos de conteo usando solo componentes conectadas, sin división de aguas. Análisis cualitativo de los casos en que varias rocas quedan unidas en una sola región y el conteo resulta subestimado.
 - 7 Introducción de la transformada de distancia y de un esquema inicial de división de aguas para separar rocas en contacto. Pruebas sobre unas pocas imágenes y documentación de aciertos y errores.
 - 8 Ajuste de los parámetros de la división de aguas —suavizado previo, supresión de máximos débiles— y observación de la sobresegmentación que aparece en ciertos paisajes. Registro de casos problemáticos.
 - 9 Consolidación del procedimiento completo, desde la máscara original hasta el número de rocas por imagen. Correcciones iterativas de parámetros a partir de los ejemplos difíciles.
 - 10 Ejecución del procedimiento sobre el conjunto seleccionado. Revisión de resultados atípicos, comparación visual con las imágenes originales y estadísticos descriptivos de los indicadores.
-

Sem. Actividades previstas

- 11 Análisis detallado de los resultados e identificación de patrones según el tipo de terreno. Notas sobre las limitaciones del método y sobre los casos en que el conteo falla con mayor frecuencia.
 - 12 Redacción de la metodología, con ejemplos gráficos del procedimiento y explicaciones dirigidas a lectores no especialistas en visión por computador.
 - 13 Redacción de resultados y discusión. Integración de las observaciones sobre sobresegmentación, sensibilidad a los parámetros y diferencias entre paisajes.
 - 14 Espacio de maniobra para una actividad opcional de validación con observadores humanos —conteos aproximados por bandas— o, de no ser viable, para revisar los experimentos y mejorar la presentación de figuras y tablas.
 - 15 Cierre: revisión completa del documento, verificación de que el código y los datos se ejecutan de forma reproducible, armonización del estilo y preparación de la versión final.
-

Las semanas 1 a 3 se dedican a preparar el terreno: revisar la literatura, dejar listo el entorno y familiarizarse con las imágenes y máscaras. Entre las semanas 4 y 9 se construye y ajusta de forma gradual el procedimiento, aceptando que algunos parámetros se afinan por iteración y no en un único intento. Las semanas 10 a 13 se concentran en aplicarlo sobre el conjunto elegido, analizar los resultados y plasmarlos en el documento. La semana 14 queda como margen de maniobra, y la 15 se reserva para el cierre y la verificación de reproducibilidad.

Ejecución frente a lo planificado

El plan se cumplió en sus fases principales. Conviene, no obstante, consignar tres diferencias entre lo previsto y lo ejecutado, porque afectan al alcance de los resultados.

La validación con observadores se realizó, y dos veces. La semana 14 la contemplaba como actividad *opcional*. Se llevó a cabo, y la primera ronda reveló defectos en el propio instrumento de medición que obligaron a rediseñarlo y repetirla; la subsección 4.2.2 documenta ambas rondas.

Se añadió un contraste con aprendizaje automático. No estaba previsto en el plan. Se incorporó al constatar que el procedimiento necesitaba una referencia externa frente a la cual situar su desempeño.

Se añadió una extensión aplicada. El sistema de avisos de terreno y la aplicación de consulta descritos en la subsección 4.1.6 surgieron de la ejecución y no figuraban en el cronograma inicial.

Capítulo 4

Resultados y evaluación

4.1. Resultados, análisis e interpretación

4.1.1. Conjunto analizado

El procedimiento se ejecutó sobre las 16.064 imágenes de la cámara de navegación de *Cu-riosity* que disponen de máscara de entrenamiento. La Figura 4.1 ilustra el flujo completo sobre una escena representativa: imagen original, máscara de AI4Mars, binaria depurada, transformada de distancia con las semillas detectadas y resultado del conteo.




Figura 4.1: Procedimiento paso a paso sobre una escena con varias rocas: imagen original, máscara de AI4Mars, binaria depurada, transformada de distancia con las semillas y resultado del conteo.

Cada imagen recibió una bandera de calidad que resume su aptitud para cada indicador (Tabla 4.1, Figura 4.2).

Tabla 4.1: Composición del conjunto según la bandera de calidad.

Bandera	Significado	Imágenes	%
ok	Contiene roca grande; apta para ambos indicadores	2193	13,7
no_bigrock	Contiene roca, pero sin roca grande que contar	8458	52,7
no_rock	Etiquetada, sin roca	4950	30,8
mostly_null	Más del 95 % sin etiqueta	300	1,9
empty	Sin ningún píxel etiquetado	163	1,0




Figura 4.2: Composición del conjunto analizado según la bandera de calidad.

La fracción de escena efectivamente etiquetada tiene una mediana de 0,58: algo más de la mitad de cada imagen recibió etiqueta, y el resto corresponde al cuerpo del rover, al cielo y a las distancias que el propio conjunto excluye por diseño.

4.1.2. Cobertura de roca visible (E1)

De las 16.064 imágenes, 10.817 —el 67,3 %— contienen algún píxel de roca visible. Sobre ese conjunto, la cobertura calculada según la ecuación (3.1) presenta una mediana del 96,8 % y una media del 75,1 %; medida sobre la imagen completa, la mediana es del 42,0 % y la media del 41,9 %.

La distribución (Figura 4.3) es marcadamente **bimodal**: se acumula en los extremos, con 4471 imágenes en las que la totalidad del área etiquetada es roca y un segundo grupo de cobertura nula. En total, 8339 imágenes superan el 50 % de cobertura.




Figura 4.3: Distribución de la cobertura de roca visible en sus dos versiones: sobre píxeles etiquetados y sobre la imagen completa.

Ante la posibilidad de que las coberturas altas fueran un artefacto de imágenes escasamente etiquetadas, se contrastó la cobertura con la fracción de escena etiquetada (Figura 4.4). La correlación es **prácticamente nula** ($r = -0,02$): la cobertura no depende de cuánto se etiquetó, de modo que los valores altos corresponden a escenas genuinamente dominadas por lecho rocoso y no a un sesgo de la fórmula. Este control descarta el artefacto del denominador, pero no el sesgo de la anotación, que se aborda más adelante y resulta ser de naturaleza distinta.




Figura 4.4: Cobertura frente a fracción de escena etiquetada.

4.1.3. Conteo aproximado de rocas individuales (E2)

El conteo se aplicó a las 2193 imágenes que contienen roca grande y arrojó un total de 4204 rocas, con una mediana de una roca por imagen y un máximo de veinte. El Tabla 4.2 y la Figura 4.5 recogen la distribución.

Tabla 4.2: Distribución del conteo de rocas sobre las imágenes aptas.

Rocas por imagen	Imágenes	%
0 (descartadas por los filtros)	453	20,7
1	772	35,2
2–3	613	28,0
4–9	344	15,7
10 o más	11	0,5




Figura 4.5: Distribución del conteo de rocas por imagen.

Conviene detenerse en el primer renglón: en 453 imágenes —el 20,7 % de las aptas— existen píxeles de roca grande pero ninguna región supera los filtros de área mínima y forma. La subsección 4.3.3 examina caso por caso esas imágenes y concluye que los filtros aciertan; el dato se reporta explícitamente porque delimita el alcance real del indicador.

En promedio, cada imagen apta contiene 2,25 componentes conectadas antes de la división de aguas y 1,89 rocas después. La cifra es reveladora: el paso de división de aguas **no aumenta** el conteo promedio, lo que confirma que la calibración por prominencia evitó la fragmentación masiva que producía la detección de máximos por separación mínima.

Distribución tamaño–frecuencia

Clasificando las 4204 rocas según su tamaño relativo al área de la imagen (Tabla 4.3, Figura 4.6) se obtiene una **distribución decreciente**: predominan las rocas pequeñas y la frecuencia disminuye al aumentar el tamaño.

Tabla 4.3: Distribución tamaño–frecuencia de las rocas contadas.

Clase de tamaño	Rocas	%
Pequeña ($< 0,5$ % del área)	1841	43,8
Mediana ($0,5$ % – 2 %)	1340	31,9
Grande (≥ 2 %)	1023	24,3




Figura 4.6: Distribución tamaño–frecuencia de las rocas contadas.

Esta forma coincide cualitativamente con las distribuciones tamaño–frecuencia descritas en los estudios de abundancia de rocas en sitios de aterrizaje [9, 8, 16]. La coincidencia debe leerse con cautela: aquí los tamaños son **relativos al campo de visión** y no métricos, porque el procedimiento no dispone de la escala de la escena. La comparación es de forma, no de magnitud.

La solidez media de las regiones aceptadas es de 0,912, es decir, formas compactas; solo 46 imágenes presentan solidez media inferior a 0,7, señal de contornos cóncavos o de regiones posiblemente subdivididas en exceso.

4.1.4. Composición del terreno y tipología de escenas (E3)

Además de los dos indicadores previstos, cada imagen se caracterizó por la proporción de cada clase sobre sus píxeles etiquetados. La composición media es de 49,8 % de lecho rocoso, 36,4 % de suelo, 12,5 % de arena y 1,3 % de roca grande. La clase dominante es el lecho rocoso en 8234 imágenes, el suelo en 5767, la arena en 1792 y la roca grande en apenas 108.

A partir de esa composición se definió la tipología de la Tabla 4.4, que la Figura 4.7 representa.

Tabla 4.4: Tipología de escenas según la composición del terreno.

Tipo	Criterio	Imágenes	%
Rocoso	roca $\geq$ 66 %	7601	47,3
Suelo	suelo $\geq$ 50 %	5723	35,6
Arenoso	arena $\geq$ 50 %	1742	10,8
Mixto	ninguna clase predomina	835	5,2
Sin etiqueta	sin píxeles clasificados	163	1,0




Figura 4.7: Tipología de escenas según la composición del terreno.

Un resultado central para la interpretación conjunta es que la cobertura y el conteo son **indicadores prácticamente independientes**: entre las imágenes aptas su correlación es de $r = 0,02$. Una escena puede estar casi totalmente cubierta por lecho rocoso continuo y no contener ninguna roca contable, o presentar poca cobertura y varios bloques aislados. Los dos indicadores describen aspectos distintos del terreno y no son redundantes.

4.1.5. Variación a lo largo del recorrido (E3)

Ordenando las imágenes por el reloj de nave incluido en su identificador —que crece monótonamente con el tiempo y sirve como aproximación del avance del recorrido— y agrupándolas en tramos de igual número de imágenes, se observa (Figura 4.8) una **alternancia clara entre tramos francamente rocosos y tramos de suelo o arena**, con concentraciones puntuales de roca grande que alcanzan hasta el 40 % de las imágenes de un tramo.




Figura 4.8: Cobertura y presencia de roca grande a lo largo del recorrido, en tramos de igual número de imágenes.

Esta lectura responde de forma directa a la pregunta sobre en qué tramos del trayecto se concentra la roca visible. Debe interpretarse como una **ordenación relativa** y no como una serie temporal calibrada, pues el eje refleja el orden de adquisición y no el sol ni la distancia recorrida.

Cabe señalar que el subconjunto es casi enteramente de la cámara izquierda del par estéreo —16.027 imágenes frente a 37 de la derecha—, por lo que no fue posible la comparación entre ojos que E3 contemplaba.

4.1.6. Extensión aplicada: de indicador a aviso operativo

Los indicadores anteriores describen el terreno, pero no dicen qué hacer con esa descripción. Como extensión del trabajo se construyó una capa que los traduce en avisos sobre las condiciones que la literatura de exploración planetaria asocia a riesgo para un vehículo, y una aplicación para consultarlos. Ambas se derivan del conjunto de resultados y no requieren reprocesar las máscaras.

Reglas de aviso

Se definieron seis reglas, cada una con un umbral explícito, el percentil de la distribución observada al que corresponde y la razón que la motiva (Tabla 4.5). Los umbrales se fijaron sobre los percentiles del propio subconjunto y no de forma arbitraria, de modo que el criterio sea discutible y ajustable en lugar de quedar oculto en el código.

Tabla 4.5: Reglas de aviso, con su umbral y la condición que pretenden capturar. La severidad distingue los avisos operativos (2 y 3) de los meramente informativos (1).

Aviso	Umbral	Sev.	Motivación
Daño en ruedas	roca grande > 5 % y solidez < 0,85	3	Abundancia de bloques con contornos angulosos: la condición asociada al desgaste prematuro documentado en <i>Curiosity</i> [19].
Obstáculo mayor	roca mayor > 15 %	3	Un bloque que domina la escena puede superar la altura franqueable.
Atrapamiento en arena	arena > 70 %	3	La arena suelta compromete la tracción; es el modo de fallo que inmovilizó a <i>Spirit</i> .
Campo de bloques	5 o más rocas	2	Muchos bloques discretos reducen las trayectorias viables aunque ninguno sea infranqueable.
Terreno rocoso	cobertura > 80 %	1	Informativa: buena tracción, pero superficie irregular.
Escena poco evaluable	más del 95 % sin etiquetar	1	Señala que la ausencia de avisos no debe leerse como ausencia de riesgo.

El nivel de riesgo de una escena se determina solo con las reglas de severidad dos o tres: las informativas no lo elevan. Se califica de riesgo **alto** cuando concurren al menos dos reglas operativas y alguna es de severidad tres, **medio** cuando hay una sola de severidad tres, y **bajo** cuando únicamente se activan reglas de severidad dos. La Figura 4.9 presenta el resultado sobre el subconjunto completo.




Figura 4.9: Escenas por nivel de riesgo, en escala logarítmica, y número de escenas que activa cada regla.

De las 16.064 escenas, 104 resultan de riesgo alto, 1359 de riesgo medio y 124 de riesgo bajo; las 14.477 restantes no activan ninguna regla operativa. La categoría *bajo* es deliberadamente estrecha —solo se alcanza cuando se activa en exclusiva la única regla de severidad dos— y por eso resulta menos frecuente que *medio*, lo que a primera vista parece una anomalía del conteo y no lo es.

El aviso más frecuente es el informativo de terreno rocoso, con 6855 escenas, lo que concuerda con la tipología de la Figura 4.7. Entre los operativos destaca el riesgo de atrapamiento en arena, con 1174 escenas, y el más restrictivo es el de daño en ruedas, con 73: exige simultáneamente abundancia de roca grande y contornos irregulares, una conjunción poco común.

Conviene subrayar el alcance de esta capa. Los avisos **heredan las limitaciones de los indicadores de los que derivan**, incluido el sesgo de la anotación documentado en la subsección 4.3.2. No constituyen una valoración de transitabilidad validada contra incidentes reales —no existe tal registro para este subconjunto— sino una priorización de escenas para revisión, cuyo criterio queda explícito y es por tanto auditable y ajustable.

Aplicación de consulta

Para que el conjunto de resultados sea consultable sin conocimientos de programación se desarrolló una aplicación de escritorio en Python, con cuatro vistas: un resumen descriptivo del subconjunto, la distribución de avisos, un explorador que muestra para cada escena la imagen, la anotación y las rocas detectadas, y una vista de los rasgos geológicos del conjunto extendido. Se distribuye junto al código y opera sobre los mismos archivos de resultados, de modo que cualquier reejecución del procedimiento se refleja en ella sin pasos adicionales. El Anexo A detalla su estructura.

Exploración: detección de vetas

Las vetas de sulfato de calcio son depósitos precipitados por circulación de agua y constituyen el rasgo de mayor interés científico que aparece en las anotaciones del conjunto. La escala de navegación empleada en este trabajo no las etiqueta, de modo que la única vía para inventariarlas en las imágenes de *Curiosity* sería detectarlas a partir de la propia imagen. Se ensayó esa vía y **el resultado fue negativo**; se reporta porque delimita lo que cabe esperar de este material.

El procedimiento aplicó un filtro de crestas de Meijering sobre la región de lecho rocoso. Ese filtro analiza los autovalores del Hessiano para realzar estructuras curvilíneas finas y es de uso corriente en angiografía; una veta es geoméricamente el mismo tipo de objeto. Se ensayó además una variante que pondera la respuesta por el cociente azul/rojo, bajo la hipótesis de que el sulfato, blanquecino, resultaría menos rojizo que el polvo marciano. La evaluación se hizo sobre 24 escenas del conjunto extendido cuya anotación de veta se consideró plausible, midiendo la precisión frente a la tasa base (Tabla 4.6, Figura 4.10).

Tabla 4.6: Desempeño del detector de vetas sobre 24 escenas anotadas.

Medida	Sin color	Con color
Precisión media	0,261	0,267
Recall medio	0,067	0,041
Mejora sobre la tasa base	9,1×	10,2×
Escenas sin ningún acierto	11 de 24	12 de 24




Figura 4.10: Mejora sobre la tasa base por escena, ordenada de mayor a menor, y precisión frente a recall en las dos variantes.

La lectura es que **hay señal pero el detector es inutilizable**. Una mejora de nueve veces sobre la tasa base no es ruido; sin embargo recupera menos del 7 % de los píxeles de veta y falla por completo en casi la mitad de las escenas. La variante con color no aporta: la precisión apenas cambia, el recall empeora y los fallos aumentan.

La hipótesis del color se refutó con una medición propia. Sobre imágenes de la cámara de mástil de *Curiosity*, el cociente azul/rojo en las zonas claras del lecho rocoso resultó ser apenas 1,025 veces el del conjunto de la roca, y con dirección inconsistente entre escenas. Dos causas lo explican: el polvo rojizo recubre también las vetas y borra el contraste espectral, y las imágenes del conjunto son archivos comprimidos con balance de blancos aplicado, no productos radiométricos calibrados, de modo que la información espectral fina que permitiría discriminar el sulfato ya no

está presente. A ello se añade que la cámara del subconjunto es un instrumento de navegación — campo amplio, escala de grises, resolución modesta—: las vetas del cráter Gale se caracterizaron con la lupa de mano [7] y la cámara de mástil [2], no con la de navegación.

La conclusión es que perseguir esta línea exigiría datos espectrales calibrados, que no forman parte de AI4Mars. Se documenta para que el ensayo no se repita sin conocer sus límites.

4.2. Evaluación y validación

4.2.1. Contraste con etiquetas de experto

El conjunto incluye 322 máscaras etiquetadas por especialistas con acuerdo del 100 %. Se ejecutó sobre ellas el mismo procedimiento, sin modificar ningún parámetro, y se comparó con las máscaras colaborativas (Tabla 4.7, Figura 4.11).

Tabla 4.7: Comparación de indicadores entre máscaras colaborativas y de experto.

Indicador	Colaborativas	Experto
Cobertura mediana (escenas con roca)	96,8 %	46,1 %
Imágenes con cobertura del 100 %	41 %	8 %
Píxeles de lecho rocoso	49 %	31 %
Píxeles de suelo y arena	50 %	69 %
Imágenes con roca grande	13,9 %	16,5 %




Figura 4.11: Comparación de la cobertura entre etiquetas colaborativas y de experto.

La discrepancia es **sistemática y de gran magnitud** en la cobertura, mientras que la presencia de roca grande y el conteo resultan comparables. La interpretación se desarrolla en la subsección 4.3.2.

4.2.2. Validación con conteo humano

La metodología comprometía un contraste entre el conteo automático y un conteo manual. Se realizó en dos rondas: una primera de 24 escenas, que sirvió de prueba piloto y reveló defectos del propio instrumento, y una segunda de 60 escenas con el diseño corregido, que es la que se reporta como resultado.

Diseño del instrumento

En cada escena se resalta la región que la anotación marcó como roca grande y se pregunta cuántas rocas se distinguen **dentro de esa región**, en una de seis bandas: cero, una a tres, cuatro a nueve, diez a veinticuatro, veinticinco a cuarenta y nueve, o cincuenta o más. Preguntar por la escena completa habría mezclado dos cuestiones distintas —si la anotación es completa y si el procedimiento la subdivide bien—, de modo que acotar la pregunta a la región anotada es lo que permite atribuir el desacuerdo. Se responde por bandas y no con cifras exactas porque el objetivo es comprobar la coincidencia en orden de magnitud, no medir una precisión inalcanzable sin verdad

de campo. El material se presenta con identificadores neutros, en orden barajado, y el resultado automático no aparece en ningún momento.

La ronda piloto empleaba cuatro bandas, la última de ellas abierta en «diez o más». Ese diseño resultó defectuoso: un procedimiento que contara ochenta rocas donde el observador distinguía una decena puntuaba como acierto exacto, de modo que la escala **favorecía sistemáticamente a los métodos que sobreestiman**. La ronda definitiva subdivide esa banda. Corrige además otros tres defectos detectados: excluye las escenas cuya región anotada no alcanza los 2000 píxeles —en la ronda piloto siete de veinticuatro eran imperceptibles y la pregunta quedaba mal planteada—, sustituye el relleno opaco por un tinte tenue que no oculta la textura que hay que examinar, y estratifica la muestra por área de la región en lugar de por la banda del propio procedimiento, que condicionaba la muestra al método evaluado.

Resultado

Sobre las 60 escenas, el acuerdo exacto de banda es del 50 %, con coeficiente kappa de Cohen de 0,13 y kappa ponderado de 0,11. Ambos corresponden a un acuerdo **escaso** en las escalas de referencia habituales. El 50 % de acuerdo aparente es engañoso: veintiséis de las treinta coincidencias se concentran en una sola celda, la de una a tres rocas.

El desacuerdo es **marcadamente asimétrico**. El procedimiento sitúa la escena en una banda inferior a la del observador en **veintiocho casos** y superior en solo **dos**. La Figura 4.12 muestra por qué.




Figura 4.12: Matriz de acuerdo entre el conteo manual por bandas y el automático, sobre 60 escenas. Las tres columnas de la derecha están vacías: el procedimiento no produce ningún conteo superior a nueve.

El rasgo decisivo de esa matriz son las **tres columnas vacías**. En ninguna de las sesenta escenas el procedimiento devuelve más de nueve rocas, mientras que el observador identificó diez o más en doce de ellas y veinticinco o más en cinco. No se trata de un sesgo que pudiera corregirse recalibrando un umbral: el procedimiento tiene un **techo estructural** en el número de rocas que puede llegar a contar sobre estas anotaciones.

Este resultado corrige la expectativa con la que se calibró el procedimiento. La preocupación durante la calibración fue la sobresegmentación —que una roca se partiera en varias—, y el criterio de prominencia se introdujo para contenerla. La validación muestra que el problema real va en sentido contrario y es de mayor magnitud de lo que la ronda piloto sugería.

Por qué el techo: la anotación no es exhaustiva

El examen de las escenas discrepantes identifica la causa, y no es algorítmica. La anotación de roca grande **no marca todas las rocas de la escena, sino algunas**.

En 36 de las 60 escenas, la clase roca grande representa menos del 20 % de la roca etiquetada; el resto se anotó como lecho rocoso. La mediana es del 9,1 %. Dicho de otro modo: de toda la roca que la anotación reconoce en una escena típica, apenas una décima parte quedó marcada como bloque discreto.

El efecto es más acusado precisamente donde más escenas hay. En las veintisiete escenas que el observador situó entre una y tres rocas, la región resaltada ocupa una mediana del 1,11 % de la imagen y del 5,4 % de la roca etiquetada. Son regiones diminutas que contienen, en efecto, una o dos rocas —y en torno a ellas, fuera de la región, la escena contiene muchas más que la anotación no recoge.

De aquí se sigue una precisión importante sobre qué mide realmente el indicador. El conteo no estima el número de rocas presentes en una escena, sino el número de bloques **dentro de la fracción de roca que el anotador decidió delimitar como roca grande**. Ambas cantidades pueden diferir en un orden de magnitud. Incluso un procedimiento perfecto sobre estas máscaras seguiría contando solo lo que la anotación delimitó.

Alcance del indicador

El resultado obliga a acotar las pretensiones de E2 más de lo que sugerían los estadísticos agregados del apartado anterior. El conteo **no** reproduce el juicio humano con fidelidad suficiente para leerse como el número de rocas de una escena, ni siquiera restringido a la región anotada. Lo que la evidencia sostiene es un uso más débil: ordenar de forma aproximada escenas según contengan o no bloques discretos delimitados, sabiendo que el valor queda sistemáticamente por debajo de lo que un observador contaría y que el procedimiento no supera las nueve rocas.

Conviene también consignar las limitaciones de la propia validación. Se empleó un único observador, de modo que no permite estimar la variabilidad entre personas, que en una tarea de este

tipo es previsiblemente considerable. Y la muestra, aunque estratificada por área de la región para no favorecer a ningún método, no es representativa del subconjunto en su conjunto.

4.2.3. Comparación con métodos de aprendizaje automático

Como referencia externa se contrastó el procedimiento con dos enfoques de aprendizaje profundo, ejecutados en equipo local.

Modelo general sin entrenamiento específico. Un modelo fundacional de segmentación [14], en su variante rápida [33], se aplicó a 50 imágenes con roca grande, restringiendo sus regiones a la zona etiquetada como roca. El acuerdo con el conteo clásico, medido por bandas, es del 52 %, con correlación de rangos de 0,45 y un error absoluto medio de 2,6 rocas (Figura 4.13). El modelo tiende a subdividir una misma roca según su textura interna y, en otras escenas, a no detectar bloques de bajo contraste.




Figura 4.13: Matriz de acuerdo entre el conteo clásico y el modelo general.

Modelo entrenado con las propias máscaras. Se entrenó un segmentador DeepLabV3 [3] por aprendizaje por transferencia para distinguir roca de no-roca, empleando 2000 imágenes de entrenamiento, 400 de validación y 400 de prueba, muestreadas de forma equilibrada entre escenas con y sin roca. Se ejecutó durante seis épocas a una resolución de 512 píxeles en un computador portátil con aceleración por unidad gráfica integrada, con un coste de entre doce y treinta y dos minutos por época. Los píxeles sin etiqueta se excluyeron tanto de la función de pérdida como del cálculo de la métrica.

Tabla 4.8: Desempeño del segmentador DeepLabV3 en el conjunto de prueba y acuerdo del indicador de cobertura derivado de sus predicciones.

Medida	Valor
IoU de la clase no-roca	0,955
IoU de la clase roca	0,925
IoU medio	0,940
Correlación de la cobertura predicha con la humana ($n = 200$)	0,950
Error absoluto medio de la cobertura	4,3 p.p.

El modelo alcanza un IoU medio de 0,940 sobre imágenes no vistas durante el entrenamiento, y la cobertura calculada a partir de sus predicciones se correlaciona en 0,950 con la obtenida de la anotación humana, con un error absoluto medio de 4,3 puntos porcentuales. La Figura 4.14 muestra que los puntos se agrupan estrechamente en torno a la recta de igualdad; las discrepancias mayores se concentran en escenas de cobertura total, donde el modelo tiende a quedarse por debajo.




Figura 4.14: Cobertura estimada por el modelo entrenado frente a la derivada de la anotación humana, sobre las 200 imágenes del conjunto de prueba.

Esa cifra, sin embargo, no puede leerse como acierto. El modelo se entrenó con máscaras colaborativas y se evaluó contra máscaras colaborativas, de modo que mide **cuánto se parece a la anotación de la que aprendió**, no cuánta roca hay. Dado que esa anotación sobreestima la roca de forma sistemática (subsección 4.3.2), cabía esperar que el modelo hubiera aprendido el sesgo junto con la señal. Esa hipótesis exigía una comprobación independiente.

Contraste del modelo con etiquetas de experto

Se evaluó el mismo modelo, sin reentrenarlo, contra las 322 máscaras de experto, que no formaron parte de su entrenamiento ni de su validación. La comparación se restringe a los píxeles que el experto etiquetó. La Tabla 4.9 recoge el contraste.

Tabla 4.9: Desempeño del segmentador según la referencia empleada para evaluarlo.

Medida	Contra colaborativas	Contra experto
IoU medio	0,940	0,843
Correlación de la cobertura	0,950	0,927
Error absoluto medio	4,3 p.p.	7,5 p.p.
Mediana del error	—	+0,0 p.p.

El desempeño baja al evaluarse fuera del dominio del que aprendió, como era previsible, pero se mantiene alto. El dato relevante es otro: el modelo resulta **esencialmente insesgado** frente al experto. La mediana del error de cobertura es de +0,0 puntos porcentuales, con un 37 % de escenas sobreestimadas y un 30 % subestimadas (Figura 4.15). **No reprodujo el sesgo de la anotación con la que fue entrenado.**




Figura 4.15: Cobertura estimada por el modelo frente a la derivada de la anotación de experto, y distribución del error, sobre las 322 escenas con máscara de especialista.

La explicación es coherente con el mecanismo del sesgo descrito en la subsección 4.3.2. Allí se estableció que la anotación colaborativa sobreestima la cobertura porque deja **sin etiquetar** mucho suelo y arena, que desaparecen del denominador de la ecuación (3.1), y no porque asigne mal la clase de los píxeles que sí etiqueta. Como el entrenamiento excluye los píxeles sin etiqueta

tanto de la función de pérdida como de la métrica, el modelo aprendió apariencia de roca a partir de píxeles correctamente etiquetados. El sesgo residía en la fórmula de agregación, no en el contenido de las etiquetas, y por eso no se transmitió al modelo.

Conviene acotar el alcance de esta conclusión. La estimación es fiable **en agregado**, no escena por escena: el error absoluto medio es de 7,5 puntos porcentuales, el 23 % de las escenas supera los diez puntos de error y cinco escenas superan los cincuenta. Sirve para caracterizar un tramo del recorrido, no para decidir sobre una imagen concreta.

Este resultado tiene una consecuencia que excede la comparación de métodos. El procedimiento clásico de este trabajo necesita una máscara humana, que no existe en el momento en que las imágenes llegan a la Tierra. El segmentador, en cambio, lee la imagen directamente. Que estime la cobertura sin sesgo frente a una referencia de experto sugiere que el indicador definido y auditado aquí **podría calcularse sin anotación humana en el bucle**, lo que se recoge entre las líneas futuras del Capítulo 5.

4.3. Implicaciones y limitaciones

4.3.1. Interpretación de los indicadores

El trabajo confirma que las máscaras de AI4Mars pueden leerse como mapas cuantitativos y no solo como insumo de entrenamiento. Los dos indicadores propuestos se obtuvieron para la totalidad del subconjunto y resultan interpretables sin conocer los detalles del procedimiento: una cobertura del 90 % describe una escena dominada por roca, y un conteo de ocho bloques describe un terreno con obstáculos discretos.

El hallazgo de que ambos indicadores son estadísticamente independientes ($r = 0,02$) refuerza la decisión de reportarlos por separado. La cobertura mide *cuánta* roca hay; el conteo mide *cómo está organizada*. Un afloramiento continuo produce cobertura máxima y conteo nulo; un campo de bloques dispersos produce lo contrario. Para aplicaciones de transitabilidad ambas facetas importan y ninguna sustituye a la otra.

4.3.2. El sesgo de la anotación colaborativa

El resultado más relevante de la validación es que la cobertura calculada sobre las máscaras colaborativas **sobreestima sistemáticamente** la proporción de roca: la mediana pasa del 96,8 % al 46,1 % cuando se emplean máscaras de experto, y la proporción de imágenes con cobertura total cae del 41 % al 8 %.

La explicación más plausible es un **sesgo de saliencia** en la tarea de anotación. La roca es visualmente prominente y fácil de delimitar; el suelo y la arena son superficies extensas y homogéneas cuya delimitación resulta tediosa y menos evidente. Al exigirse acuerdo entre anotadores, los píxeles de suelo y arena sin consenso quedan sin etiqueta y desaparecen del denominador de la ecuación (3.1), lo que eleva la fracción de roca. La composición confirma el mecanismo: los expertos etiquetan un 69 % de píxeles de suelo y arena frente al 50 % de las máscaras colaborativas.

Es importante precisar el alcance de esta limitación. **El procedimiento de cálculo no está sesgado**: aplicado a las máscaras de experto entrega valores plausibles. El sesgo reside en los datos de entrada. En consecuencia, las coberturas reportadas deben leerse como relativas al conjunto colaborativo y no como estimaciones absolutas de la abundancia de roca en el terreno. Para comparaciones entre escenas del mismo conjunto —el uso previsto— la utilidad se mantiene, porque el sesgo actúa en la misma dirección en todas ellas.

Este hallazgo trasciende el presente trabajo. Cualquier estudio que emplee las máscaras colaborativas de AI4Mars como referencia —incluidos los que entrenan modelos de segmentación y reportan índices de solapamiento contra ellas— está midiendo el acuerdo con una anotación que sobreestima la roca. El resultado de la Figura 4.14 lo ilustra: el modelo entrenado reproduce la cobertura humana con correlación de 0,950, lo que significa que ha aprendido el sesgo junto con la señal.

4.3.3. Diagnóstico de los modos de error del conteo

Al inspeccionar visualmente los resultados se observaron dos comportamientos contradictorios: escenas en las que el conteo señalaba rocas donde un observador no las percibía, y escenas

con bloques evidentes en las que el conteo era nulo. Puesto que una explicación natural sería la insuficiencia de las imágenes, se realizó un diagnóstico sistemático para atribuir cada modo de error a su causa.

La primera constatación es de orden metodológico y descarta la hipótesis más inmediata: **el procedimiento no lee las imágenes**, de modo que su calidad no puede ser la causa. Las imágenes son además de 1024×1024 píxeles, resolución completa de la cámara, y las máscaras tienen exactamente el mismo tamaño, por lo que tampoco hay pérdida por remuestreo.

La Tabla 4.10 atribuye el conteo nulo —presente en el 89,0 % de las escenas— a sus dos causas.

Tabla 4.10: Atribución de las escenas con conteo nulo.

Causa	Escenas	Naturaleza
La máscara no tiene ningún píxel de roca grande	13.838	límite de la etiqueta
Hay roca grande, pero los filtros la descartan	460	límite de los umbrales

El primer grupo representa el 86,1 % del conjunto y su componente principal son las 8458 escenas con bandera `no_bigrock`: **sí hay roca visible, pero el anotador la etiquetó como lecho rocoso**. La mediana de lecho rocoso en ese grupo es del 99,7 %, y 5762 escenas tienen más del 80 % de lecho rocoso y cero roca grande. El desequilibrio es estructural: sobre las escenas con roca, el lecho rocoso aporta el 97,5 % de la roca etiquetada y la roca grande solo el 2,5 %, y E2 cuenta únicamente esta última.

La Figura 4.16 muestra el caso con toda claridad: una escena repleta de bloques individuales perfectamente distinguibles, etiquetada en su totalidad como una sola región de lecho rocoso, sobre la que el conteo devuelve cero.




Figura 4.16: Escena con bloques individuales evidentes, etiquetada íntegramente como lecho rocoso. El conteo devuelve cero porque la clase roca grande no está presente en la máscara.

El segundo grupo —460 escenas, el 2,9 %— se revisó caso por caso y los filtros **aciertan**: se trata de motas de pocos píxeles, con un ejemplo de una única región de doce píxeles frente al umbral de 524, o de bandas muy alargadas trazadas sobre el horizonte, descartadas por relación de aspecto. No conviene relajar los umbrales.

Por el lado de los falsos positivos, la Tabla 4.11 recoge las tres fuentes identificadas.

Tabla 4.11: Fuentes de conteo excesivo.

Fuente	Magnitud	Naturaleza
Subdivisión por división de aguas	423 de 1766 escenas	algoritmo
Artefacto de anotación	43 escenas	etiqueta
Anotación en contorno hueco	0,2 % de las escenas	anecdótico

La subdivisión afecta al 24,0 % de las escenas que cuentan y esas escenas aportan 1717 de las 4204 rocas, de modo que es la limitación algorítmica cuantitativamente más importante. La Figura 4.17 ilustra el mecanismo sobre un afloramiento.




Figura 4.17: Subdivisión de un afloramiento continuo por la división de aguas.

Los artefactos de anotación constituyen el falso positivo más llamativo. La Figura 4.18 muestra una escena en la que solo el 2,0 % de los píxeles está etiquetado y todo ese 2 % se marcó como roca grande, de modo que la roca mayor ocupa el 100 % del área válida. Estos casos explican por qué el indicador de tamaño relativo alcanza valores extremos, y advierten contra su lectura literal en escenas de fracción etiquetada muy baja.




Figura 4.18: Escena con solo el 2,0 % de los píxeles etiquetados, marcados en su totalidad como roca grande. La roca resultante ocupa el 100 % del área válida.

La anotación en forma de contorno hueco se midió sobre 600 escenas con roca grande y resultó **rara**: una región de 1019 examinadas. Se reporta por completitud, pero no admite generalización ni justifica un filtro adicional.

4.3.4. El techo del conteo no está en las imágenes

Un contraste adicional cierra el diagnóstico. Los conjuntos de máscaras de experto que el propio AI4Mars incluye contienen **menos** roca grande, no más, y la proporción disminuye a medida que se exige mayor acuerdo entre anotadores (Tabla 4.12).

Tabla 4.12: Presencia de roca grande según la fuente de etiqueta y el nivel de acuerdo exigido. La cobertura mediana se calcula aquí sobre todas las escenas del conjunto —no solo sobre las que contienen roca—, por lo que difiere de la reportada en la Tabla 4.7.

Fuente	Escenas	Con roca grande	Conteo medio	Cobertura mediana
Colaborativas	16.064	13,9 %	0,26	58,6 %
Experto, nivel 1	322	16,5 %	0,30	12,5 %
Experto, nivel 2	322	6,2 %	0,10	7,7 %
Experto, nivel 3	322	1,6 %	0,03	0,8 %

La conclusión es que la rareza de la clase roca grande **no es un defecto de la anotación colaborativa corregible con mejores anotadores**: es una propiedad de la taxonomía. La clase lecho rocoso, definida como roca en continuidad con el sustrato, absorbe la mayoría de los bloques que un lector humano contaría como rocas individuales, y lo hace de forma más acentuada cuanto más estricto es el criterio de acuerdo. El techo de E2 es la definición de la clase, no la calidad del dato ni la resolución de la imagen.

4.3.5. Una vía para levantar ese techo

De lo anterior se sigue una consecuencia constructiva. No hacen falta imágenes mejores; hace falta **usar** las que ya existen. La máscara indica *dónde* hay roca, y lo hace con datos abundantes; la imagen puede indicar *cuántos* bloques hay dentro de esa región.

Se realizó una prueba de concepto sobre la escena de la Figura 4.16 —98,8 % de la escena etiquetada como roca, cero píxeles de roca grande, conteo nulo—, combinando el gradiente de intensidad de la imagen como relieve, semillas de prominencia en los interiores planos restringidas

a la región de roca de la máscara, y división de aguas con los mismos filtros de área de E2. El resultado (Figura 4.19) son 456 bloques cuyas fronteras siguen las fracturas visibles en la imagen. El procedimiento sigue siendo clásico y no entrena ningún modelo.




Figura 4.19: Prueba de concepto: la máscara indica dónde hay roca y el gradiente de la imagen cuántos bloques la componen. Donde el conteo actual devuelve cero, el enfoque híbrido recupera 456 bloques con fronteras que siguen las fracturas visibles.

Esta prueba se reporta como exploración y no como resultado. La cifra de 456 bloques es con toda probabilidad un sobreconteo, y el método requiere calibración y validación contra conteo humano antes de poder reportarse como indicador. Su valor aquí es demostrativo: prueba que la información que E2 no está viendo se encuentra en la imagen y no ausente del dato.

4.3.6. Limitaciones restantes

Además de las anteriores, conviene consignar cuatro limitaciones.

Ausencia de escala métrica. Los tamaños son relativos al campo de visión. Sin la geometría de la cámara o la información estereoscópica, no es posible expresarlos en centímetros ni construir distribuciones tamaño–frecuencia comparables con la literatura en magnitud. La cámara de navegación es un par estéreo, de modo que la vía existe, pero el subconjunto disponible es casi enteramente monocular.

Alcance de la validación humana. La validación de la subsección 4.2.2 se realizó con un único observador, de modo que no permite separar el desacuerdo atribuible al procedimiento del inherente a la tarea, que en un juicio de este tipo es previsiblemente considerable. Debe leerse como una comprobación cualitativa sobre una muestra estratificada, no como una medición con intervalos de confianza estrechos.

Subdivisión residual y subconteo. El criterio de prominencia redujo sustancialmente la fragmentación, pero no la eliminó: el 24,0 % de las escenas que cuentan presentan más rocas que componentes conectadas. La validación humana muestra, sin embargo, que el sesgo neto va en sentido opuesto y es de mayor magnitud —el procedimiento no supera las nueve rocas en ninguna de las 60 escenas evaluadas—, de modo que ambos efectos coexisten en escenas distintas y no se cancelan.

Alcance del subconjunto. Los resultados corresponden a una cámara de un rover en una región. No se extienden sin más a otras misiones, otras cámaras ni otros terrenos.

Capítulo 5

Conclusiones y recomendaciones

5.1. Conclusiones

5.1.1. Sobre la pregunta de investigación

La pregunta era si es posible cuantificar, a partir de las máscaras de AI4Mars, la cobertura de roca visible y el número aproximado de rocas individuales por imagen mediante un flujo de parámetros explícitos y resultados reproducibles. La respuesta es afirmativa, con un matiz importante que distingue las dos mitades.

La **cobertura** se calcula de forma robusta y con datos abundantes: quedó definida para el 67,3 % de las 16.064 escenas del subconjunto, y el control contra la fracción de escena etiquetada ($r = -0,02$) descarta que sus valores altos sean un artefacto de la fórmula. Es un indicador utilizable.

El **conteo de rocas** se calcula correctamente donde la etiqueta lo permite, pero la etiqueta lo permite en pocos sitios: solo el 13,9 % de las escenas contiene algún píxel de la clase roca grande. El indicador es válido en su dominio y el procedimiento no falla; lo que falla es la disponibilidad del dato de entrada.

5.1.2. Sobre los objetivos específicos

Los cinco objetivos se cumplieron, con el alcance que sigue.

E1 produjo la cobertura para todo el subconjunto, en dos versiones complementarias — sobre píxeles etiquetados y sobre la imagen completa— acompañadas de la fracción etiquetada que permite juzgar la diferencia.

E2 produjo el conteo para las 2193 imágenes aptas, con un total de 4204 rocas y una distribución tamaño–frecuencia decreciente, coherente en forma con la literatura de abundancia de rocas. La calibración por prominencia resolvió la sobresegmentación que hacía inservible la primera versión del procedimiento: el conteo medio por imagen apta (1,89) es inferior al número medio de componentes conectadas (2,25), lo que confirma que la división de aguas no fragmenta masivamente.

E3 caracterizó la composición del terreno y definió una tipología de escenas, y mostró la alternancia entre tramos rocosos y arenosos a lo largo del recorrido. Su componente de comparación entre cámaras no pudo ejecutarse: el subconjunto es casi enteramente monocular, con 16.027 imágenes del ojo izquierdo frente a 37 del derecho.

E4 entregó el conjunto de recursos reproducibles: código modular con parámetros explícitos, guiones de ejecución, registro de versiones y un archivo tabular con veinticuatro indicadores por imagen para las 16.064 escenas.

E5 identificó los patrones, los casos atípicos y las limitaciones, y es de donde provienen los dos hallazgos que el trabajo considera sus aportes principales.

5.1.3. Sobre la independencia de los indicadores

Cobertura y conteo resultaron estadísticamente independientes ($r = 0,02$). Este resultado no era evidente de antemano y tiene consecuencia práctica: los dos indicadores no son redundantes y ninguno puede sustituir al otro. La cobertura mide cuánta roca hay; el conteo, cómo está organizada. Un afloramiento continuo produce cobertura máxima y conteo nulo; un campo de bloques dispersos, lo contrario. Cualquier uso operativo del resultado —la evaluación de transitabilidad, por ejemplo— necesita ambas facetas.

5.1.4. Sobre la calidad de la anotación

El contraste con las 322 máscaras de experto reveló que la anotación colaborativa **sobrees-
tima de forma sistemática** la cobertura de roca: la mediana pasa del 96,8 % al 46,1 %, y la pro-

porción de escenas con cobertura total cae del 41 % al 8 %. El mecanismo propuesto es un sesgo de saliencia: la roca es visualmente prominente y fácil de delimitar, mientras que el suelo y la arena son superficies extensas cuya anotación es tediosa; los píxeles sin consenso quedan sin etiqueta y desaparecen del denominador.

El procedimiento de cálculo no está sesgado —aplicado a las máscaras de experto entrega valores plausibles—, de modo que el sesgo reside en los datos. La consecuencia es que las coberturas reportadas deben leerse como relativas al conjunto colaborativo. Y la consecuencia de mayor alcance es que afecta a cualquier trabajo que emplee esas máscaras como referencia, incluidos los que entrenan modelos de segmentación y reportan índices de solapamiento contra ellas: esas cifras miden el acuerdo con una anotación sesgada.

5.1.5. Sobre la transmisión del sesgo a un modelo entrenado

Cabía esperar que un modelo entrenado con las máscaras colaborativas heredase su sesgo. La comprobación lo desmiente. Evaluado sin reentrenar contra las 322 máscaras de experto, el segmentador binario alcanza un IoU medio de 0,843 y una correlación de la cobertura de 0,927, y sobre todo resulta **esencialmente insesgado**: la mediana del error es de +0,0 puntos porcentuales.

La razón es que el sesgo de la anotación opera por el **denominador** —los píxeles de suelo y arena que quedan sin etiquetar y desaparecen del cálculo— y no por error de clase en los píxeles etiquetados. Como el entrenamiento excluye los píxeles sin etiqueta, el modelo aprendió apariencia de roca correcta.

La conclusión debe acotarse en dos sentidos. El modelo estima **cobertura, no conteo**: distingue roca de no-roca y no separa bloques, de modo que no sustituye a E2. Y su estimación es fiable en agregado y no escena por escena, con un error absoluto medio de 7,5 puntos porcentuales. Con esas reservas, el resultado sugiere que el indicador definido y auditado en este trabajo podría calcularse sin anotación humana, lo que abre la vía que se recoge entre las recomendaciones.

5.1.6. Sobre el acuerdo con el juicio humano

La validación por bandas sobre 60 escenas arrojó un acuerdo exacto del 50 %, con kappa de Cohen de 0,13 y kappa ponderado de 0,11: un acuerdo escaso. La cifra de acuerdo es además engañosa, porque veintiséis de las treinta coincidencias se concentran en una sola banda. El desacuerdo es marcadamente asimétrico —el procedimiento queda por debajo del observador en veintiocho casos y por encima en dos— y su rasgo decisivo es que **en ninguna escena el procedimiento supera las nueve rocas**, mientras el observador identificó diez o más en doce de ellas.

De este resultado se extraen tres conclusiones. La primera es que el conteo **no** reproduce el juicio humano con fidelidad suficiente para leerse como una medida de la cantidad de rocas de una escena; sostiene, a lo sumo, la distinción aproximada entre escenas con y sin bloques discretos delimitados.

La segunda corrige la expectativa con la que se calibró el procedimiento. El riesgo que se temía era la sobresegmentación, y contra ella se introdujo el criterio de prominencia. El sesgo real va en **sentido opuesto** y tiene un techo estructural, no ajustable mediante umbrales.

La tercera precisa qué mide el indicador. La anotación de roca grande **no marca todas las rocas de una escena, sino algunas**: en 36 de las 60 escenas representa menos del 20 % de la roca etiquetada, con una mediana del 9,1 %. El conteo estima por tanto el número de bloques dentro de la fracción que el anotador decidió delimitar, no el número de rocas presentes, y ambas cantidades pueden diferir en un orden de magnitud.

5.1.7. Sobre el origen de los errores del conteo

El diagnóstico sistemático de los modos de error descartó la explicación intuitiva —la calidad de las imágenes— y localizó el límite en la taxonomía de las etiquetas.

De las escenas con conteo nulo, el 86,1 % carece por completo de píxeles de roca grande, y su grupo principal son 8458 escenas donde **sí hay roca visible, etiquetada como lecho rocoso**. Globalmente, el lecho rocoso aporta el 97,5 % de la roca anotada y la roca grande solo el 2,5 %.

Solo el 2,9 % de las escenas pierde el conteo por los umbrales del procedimiento, y la revisión caso por caso mostró que en esas escenas los filtros aciertan.

El contraste decisivo es que las máscaras de experto contienen **menos** roca grande, no más, y la proporción cae al endurecer el criterio de acuerdo, del 16,5 % al 1,6 %. La rareza de la clase no es, por tanto, un defecto del *crowdsourcing* corregible con mejores anotadores: es una propiedad de la taxonomía, en la que la clase lecho rocoso absorbe los bloques que un lector humano contaría como rocas individuales.

5.1.8. Sobre la detección de vetas

Se ensayó detectar vetas minerales a partir de la imagen, por ser el rasgo de mayor interés científico presente en las anotaciones. El resultado fue negativo y se reporta como tal: el detector mejora nueve veces la tasa base, de modo que hay señal, pero recupera menos del 7 % de los píxeles de veta y falla por completo en casi la mitad de las escenas. La hipótesis de que el color permitiría discriminar el sulfato quedó refutada por una medición propia, que halló un contraste azul/rojo de apenas 1,025 veces y con dirección inconsistente.

La explicación es instrumental y no algorítmica: el polvo recubre las vetas, las imágenes del conjunto son archivos comprimidos con balance de blancos y no productos radiométricos calibrados, y la cámara del subconjunto es un instrumento de navegación. Perseguir esta línea exigiría datos espectrales que AI4Mars no contiene.

5.2. Aportes

El trabajo deja cuatro aportes que conviene distinguir por su naturaleza.

Un procedimiento y un conjunto de resultados. Un flujo documentado, auditable y de bajo costo computacional que deriva veinticuatro indicadores por imagen para 16.064 escenas, ejecutable en procesador convencional sin conjunto de entrenamiento. Constituye una línea de base contra la

cual comparar métodos más costosos, y el conjunto de resultados es reutilizable con independencia del procedimiento que lo generó.

La cuantificación del sesgo de la anotación colaborativa. Es, a juicio de este trabajo, su aporte más transferible. La comunidad que emplea AI4Mars mide el desempeño de sus modelos por el acuerdo con las máscaras colaborativas; documentar que esas máscaras sobreestiman la roca de forma sistemática, y estimar la magnitud del efecto, es información pertinente para todos esos trabajos y no solo para este.

La atribución de los límites del conteo. Mostrar con datos que el techo del conteo está en la definición de las clases y en la granularidad del trazado, y no en la resolución de las imágenes ni en la pericia de los anotadores, delimita con precisión qué cabe esperar de AI4Mars para tareas de conteo de instancias. La validación humana lo confirma desde el otro extremo: el desacuerdo se concentra donde la anotación agrupa en un polígono lo que el observador separa. Es un resultado negativo, y por eso mismo útil: ahorra a otros recorrer un camino cerrado.

Una capa aplicada sobre los indicadores. Los indicadores se tradujeron en seis reglas de aviso con umbrales explícitos y justificados, y en una aplicación que hace el conjunto de resultados consultable sin programar. El valor no está en la sofisticación técnica sino en que el criterio queda a la vista: cada umbral lleva asociado el percentil que lo fija y la razón que lo motiva, de modo que es discutible y ajustable por quien use el sistema, en lugar de quedar oculto.

Una vía constructiva. La prueba de concepto del enfoque híbrido —la máscara indica dónde hay roca, el gradiente de la imagen cuántos bloques la componen— muestra que la información que falta está en la imagen y no ausente del dato. Se reporta como exploración, no como resultado validado.

5.3. Recomendaciones

5.3.1. Para el uso de los resultados de este trabajo

Las coberturas deben emplearse para **comparar escenas del mismo conjunto**, no como estimaciones absolutas de abundancia de roca. El sesgo documentado actúa en la misma dirección en todas las escenas, de modo que preserve el orden relativo aunque desplace el nivel.

El conteo debe acompañarse siempre de su bandera de calidad. Un cero puede significar tanto ausencia de rocas como ausencia de la etiqueta que permite contarlas, y son situaciones muy distintas que el conjunto de resultados distingue explícitamente.

Los indicadores de tamaño relativo no deben leerse literalmente en escenas de fracción etiquetada muy baja, donde los artefactos de anotación producen valores extremos.

5.3.2. Para trabajos futuros sobre AI4Mars

Calibrar y validar el enfoque híbrido. Es la continuación natural. Requiere fijar los parámetros del gradiente y de las semillas sobre una muestra de escenas de terreno variado y, sobre todo, validar el conteo resultante contra conteo humano. Sin esa validación el método no puede reportarse como indicador.

Ampliar la validación humana. La validación definitiva empleó 60 escenas y un único observador, de modo que no permite estimar la variabilidad entre personas, que en una tarea de este tipo es previsiblemente considerable. Repetirla con varios observadores daría un intervalo de confianza a los coeficientes reportados y permitiría separar el desacuerdo atribuible al procedimiento del inherente a la tarea.

Recuperar la escala métrica. La cámara de navegación es un par estéreo. Un subconjunto con ambos ojos disponibles permitiría estimar distancias y expresar los tamaños en unidades métricas, lo que haría los resultados comparables en magnitud —y no solo en forma— con la literatura de abundancia de rocas.

Reconsiderar la frontera entre clases. Para tareas de conteo de instancias, la distinción entre lecho rocoso y roca grande tal como está operacionalizada en AI4Mars resulta poco funcional. Un esfuerzo de anotación orientado explícitamente a instancias —delimitando bloques individuales en lugar de regiones de clase— produciría un dato cualitativamente distinto. La taxonomía geológica extendida que el conjunto incluye para otra misión, con clases de bloque suelto y guijarro, apunta en esa dirección y merece examinarse.

5.3.3. Para quienes evalúan modelos con AI4Mars

Reportar el desempeño únicamente como acuerdo con las máscaras colaborativas sobreestima la calidad efectiva del modelo, porque incorpora el sesgo de la referencia. Se recomienda reportar además el desempeño sobre el subconjunto de máscaras de experto que el propio conjunto incluye, y hacerlo por clase, dado que la magnitud del sesgo difiere sustancialmente entre la roca y las superficies sueltas.

Glosario

Abundancia de rocas Proporción de la superficie ocupada por rocas por encima de un cierto tamaño, expresada habitualmente como porcentaje del área total. En estudios de selección de sitio de aterrizaje, una abundancia baja indica terreno relativamente limpio y valores altos señalan zonas peligrosas para un módulo o un rover.

Anotación colaborativa Modalidad de trabajo en la que personas no especialistas participan en tareas científicas, por ejemplo etiquetando imágenes. En AI4Mars miles de voluntarios marcaron el tipo de terreno píxel a píxel y las anotaciones se combinaron exigiendo acuerdo entre anotadores.

Apertura morfológica Erosión seguida de dilatación con el mismo elemento estructurante. Elimina manchas pequeñas y ruido aislado sin alterar sensiblemente las regiones grandes.

Área de una componente Número de píxeles que pertenecen a una misma región conectada. Es una medida directa del tamaño proyectado del objeto.

Caja envolvente Rectángulo alineado con los ejes de la imagen que contiene por completo una componente conectada. De ella se derivan el ancho, el alto y la relación de aspecto.

Cierre morfológico Dilatación seguida de erosión. Rellena huecos pequeños y une regiones separadas por una distancia mínima.

Cobertura de roca visible Porcentaje de píxeles etiquetados de una imagen que corresponden a lecho rocoso o roca grande. Resume cuán rocoso es el terreno de la escena.

Componente conectada Conjunto de píxeles activos de una imagen binaria en el que cada píxel se alcanza desde los demás mediante pasos entre vecinos. Con conectividad de ocho vecinos se admiten también los pasos diagonales.

División de aguas Técnica de segmentación que interpreta una imagen —o una transformación de ella— como un relieve topográfico. A partir de semillas situadas en los puntos altos, las regiones crecen hasta encontrarse y definen las fronteras. Aquí se aplica sobre la transformada de distancia para separar rocas que aparecen pegadas.

Elemento estructurante Máscara pequeña que define la vecindad empleada por una operación morfológica.

Lecho rocoso Roca expuesta en continuidad con el sustrato, frente a los bloques sueltos apoyados sobre el regolito. En la escala NAV corresponde a la clase *bedrock*.

Máscara binaria Imagen de dos valores en la que los píxeles activos señalan la clase de interés y el resto el fondo.

Máscara de segmentación por píxel Imagen del mismo tamaño que la original en la que cada píxel guarda un entero que identifica la clase de terreno a la que pertenece.

Máximo de prominencia Máximo local cuya altura sobre el entorno supera un umbral dado. Filtrar por prominencia descarta las crestas espurias que subdividen una región continua.

Píxel sin etiqueta Píxel que la anotación deja sin clase asignada, por falta de acuerdo entre anotadores o por corresponder al cuerpo del rover, al cielo o a distancias mayores que el alcance definido. Se excluye de todos los cálculos.

Relación de aspecto Cociente entre el lado mayor y el lado menor de la caja envolvente. Sirve para descartar formas excesivamente alargadas, poco plausibles como roca aislada.

Reproducibilidad Propiedad de un análisis que permite obtener los mismos resultados a partir de los mismos datos siguiendo el procedimiento descrito, con el código, los parámetros y las versiones de biblioteca documentados.

Segmentación semántica Tarea de asignar a cada píxel de una imagen una etiqueta de clase, sin distinguir entre instancias de la misma clase.

Semilla o marcador Punto o región de partida a partir de la cual crece un dominio en la división de aguas. Cada semilla origina, en principio, una región de salida.

Solidez Cociente entre el área de una región y el área de su envolvente convexa. Valores próximos a uno indican formas compactas; valores bajos señalan contornos cóncavos o subdivisión excesiva.

Transformada de distancia Imagen en la que cada píxel activo guarda la distancia al píxel de fondo más cercano. Sus máximos locales se sitúan en los centros de las regiones y sirven como semillas naturales.

Distribución tamaño–frecuencia Relación entre el tamaño de las rocas y su número. En superficies planetarias suele ser decreciente: predominan las rocas pequeñas y la frecuencia cae al aumentar el tamaño.

Capítulo A

Material complementario

A.1. Esquema del conjunto de resultados

El archivo tabular de resultados contiene una fila por imagen y veinticuatro columnas, organizadas en cinco grupos. La Tabla A.1 las describe.

Tabla A.1: Esquema del conjunto de resultados.

Grupo	Columna	Descripción
Identificación	image_id	Identificador de la escena.
	rover	Misión de procedencia.
	camera	Cámara de procedencia.
	eye	Ojo del par estéreo (L o R).
	sol	Día marciano, si está disponible.
Cobertura (E1)	rock_coverage_pct	Roca sobre píxeles etiquetados.
	coverage_total_pct	Roca sobre la imagen completa.
	frac_valid	Fracción de escena etiquetada.
Composición	pct_soil	Proporción de suelo.
	pct_bedrock	Proporción de lecho rocoso.
	pct_sand	Proporción de arena.
	pct_bigrock	Proporción de roca grande.
	dominant_class	Clase mayoritaria.
	scene_type	Tipología de escena.
Conteo (E2)	n_bigrock	Píxeles de roca grande.
	n_rocks	Rocas tras división de aguas y filtros.
	n_raw_components	Componentes conectadas previas.
	largest_rock_pct	Tamaño de la roca mayor.
	mean_rock_area_px	Área media de las rocas.
	n_small	Rocas pequeñas.
	n_medium	Rocas medianas.
	n_large	Rocas grandes.
Calidad	mean_solidity	Solidez media de las regiones aceptadas.
	quality_flag	Bandera de aptitud de la escena.

A.2. Casos adicionales del procedimiento

Las figuras de esta sección muestran el procedimiento sobre escenas de tipos de terreno distintos, y sirven de complemento a la Figura 4.1.




Figura A.1: Procedimiento sobre una escena con una roca aislada.




Figura A.2: Procedimiento sobre una escena con varios bloques próximos.




Figura A.3: Procedimiento sobre una escena de terreno mixto.



Figura A.4: Procedimiento sobre una escena dominada por afloramiento.

A.3. Modos de error descartados por los filtros

Las dos figuras siguientes documentan los casos que el Tabla 4.10 atribuye a los umbrales del procedimiento, y respaldan la afirmación de que en esas escenas los filtros aciertan.



Figura A.5: Escena con una única región de roca grande de doce píxeles, por debajo del umbral de 524. El conteo devuelve cero correctamente.




Figura A.6: Escena en la que la anotación de roca grande es una banda alargada trazada sobre el horizonte, descartada por relación de aspecto.



Figura A.7: Caso atípico de anotación trazada como contorno hueco. La división de aguas fragmenta el anillo resultante. Se midió que este patrón afecta a cerca del 0,2 % de las escenas con roca grande.

A.4. Documentación técnica de la extensión aplicada

Esta sección documenta los componentes descritos en la subsección 4.1.6.

Capa de avisos

Se implementa como un módulo independiente que opera sobre el archivo de resultados y le añade cuatro columnas: las claves de los avisos activados, su número, la severidad máxima y

el nivel de riesgo resultante. Cada regla se declara como un objeto con su clave, su título legible, su severidad, la condición —una función sobre la fila de resultados—, el criterio en texto y su motivación. Esa estructura permite añadir, retirar o reajustar reglas sin tocar la lógica de evaluación, y garantiza que todo umbral quede acompañado de su justificación en el mismo lugar del código.

La evaluación no reprocesa máscaras: recorre el archivo de resultados, de modo que recalcular los avisos sobre las 16.064 escenas es inmediato. Las salidas son la tabla completa con las columnas añadidas, un catálogo de las reglas con sus umbrales y un resumen agregado por nivel y por tipo de aviso.

Aplicación de consulta

Aplicación de escritorio en Python construida sobre una biblioteca de componentes gráficos modernos, con la paleta institucional de la agencia responsable del conjunto de datos. La ventana se organiza en una barra lateral de navegación y cuatro vistas:

Resumen Estadísticos descriptivos del subconjunto y composición del terreno.

Avisos Distribución por nivel de riesgo y por tipo de regla, con el detalle del criterio que motivó cada aviso.

Explorador Para la escena seleccionada, la imagen original, la anotación del terreno y las rocas detectadas por el procedimiento, en paneles contiguos.

Geología Presencia de los rasgos de la taxonomía extendida en el conjunto de la misión posterior, incluidas las vetas.

Las figuras se generan en el momento a partir de los mismos archivos de resultados que respaldan este documento, de modo que la aplicación no mantiene una copia propia de los datos y cualquier reejecución del procedimiento se refleja en ella sin pasos adicionales.

Exploración de rasgos geológicos

El conjunto de datos incluye, para la misión posterior a la estudiada, una taxonomía geológica más detallada que la escala de navegación: distingue subtipos de lecho rocoso, roca suelta, guijarros y vetas. Se recorrieron sus 8497 máscaras registrando la presencia y extensión de cada rasgo. Las vetas aparecen en 294 escenas, el 3,5 %, de las cuales 150 presentan una geometría compatible con una veta genuina —alargada y de área reducida— y 69 resultan dudosas.

Ese recorrido tiene un interés que excede la exploración de vetas y se recoge entre las recomendaciones del Capítulo 5: la clase de *roca suelta* de esa taxonomía aparece en una proporción muy superior a la de *roca grande* en la escala de navegación, lo que la convierte en la vía natural para sortear el techo del conteo documentado en la subsección 4.3.3.

A.5. Recursos reproducibles

Los recursos que respaldan el trabajo se organizan como sigue.

Módulos de cálculo Implementan la lectura de máscaras, el cálculo de cobertura, el conteo de rocas, los descriptores de composición y geometría, y la orquestación que produce una fila de resultados por imagen. Las funciones reciben arreglos y devuelven arreglos o números, sin efectos secundarios, y todos los umbrales se pasan como argumentos con valores por defecto documentados.

Guiones de ejecución Automatizan el recorrido del subconjunto, la generación de las figuras del documento, el diagnóstico de los modos de error y las comparaciones con los métodos de aprendizaje automático.

Conjunto de resultados Archivo tabular con los veinticuatro indicadores para las 16.064 escenas, según el esquema de la Tabla A.1.

Especificación del entorno Archivo de definición del entorno con las dependencias, complementado por el registro de versiones exactas del Tabla 3.3.

El conjunto de datos AI4Mars no se distribuye con estos recursos, dado su volumen. El código lo referencia mediante una ruta configurable, de modo que debe descargarse de la fuente original [24].

Referencias

- [1] Osama Alkawi y col. «Texture-based segmentation for sand and rock in Mars images». En: *Advances in Space Research* 76 (2025). DOI: 10.1016/j.asr.2025.05.034.
- [2] James F. Bell III y col. «The Mars Science Laboratory Curiosity rover Mastcam instruments: Preflight and in-flight calibration, validation, and data archiving». En: *Earth and Space Science* 4.7 (2017), págs. 396-452. DOI: 10.1002/2016EA000219.
- [3] Liang-Chieh Chen y col. «Rethinking atrous convolution for semantic image segmentation». En: *arXiv preprint arXiv:1706.05587*. 2017. DOI: 10.48550/arXiv.1706.05587.
- [4] Zhen Chen y col. «Rock abundance and erosion rate at the Zhurong landing site in southern Utopia Planitia on Mars». En: *Earth and Space Science* 9.8 (2022), e2022EA002252. DOI: 10.1029/2022EA002252.
- [5] Yuqi Dai y col. «SegMarsViT: Lightweight Mars terrain segmentation network for autonomous driving in planetary exploration». En: *Remote Sensing* 14.24 (2022), pág. 6297. DOI: 10.3390/rs14246297.
- [6] Kaichang Di y col. «Rock size–frequency distribution analysis at the Chang’e-3 landing site». En: *Geophysical Research Letters* 42.18 (2015), págs. 7406-7414. DOI: 10.1002/2015GL065493.
- [7] Kenneth S. Edgett y col. «Curiosity’s Mars Hand Lens Imager (MAHLI) investigation». En: *Space Science Reviews* 170.1–4 (2012), págs. 259-317. DOI: 10.1007/s11214-012-9910-4.
- [8] Matthew P. Golombek y col. «Rock size–frequency distributions and surface properties at the InSight landing site, Mars». En: *Journal of Geophysical Research: Planets* 126.9 (2021), e2021JE006883. DOI: 10.1029/2021JE006883.

- [9] Matthew P. Golombek y col. «Selection of the Mars Exploration Rover landing sites and rock size–frequency distributions on Mars». En: *Journal of Geophysical Research: Planets* 108.E12 (2003), pág. 8072. DOI: 10.1029/2003JE002074.
- [10] Matthew P. Golombek y col. «Selection of the Mars Science Laboratory landing site». En: *Space Science Reviews* 170.1–4 (2012), págs. 641-737. DOI: 10.1007/s11214-012-9916-y.
- [11] Christopher L. Grady y col. «A remote-sensing-based method using rockfall inventories for hazard mapping at the community scale in the Arequipa region of Peru». En: *Remote Sensing* 16.19 (2024), pág. 3732. DOI: 10.3390/rs16193732.
- [12] Xin Guo y col. «Size measurement of blasted rock fragments based on a deep neural network». En: *Measurement* 218 (2022), pág. 113207. DOI: 10.1016/j.measurement.2023.113207.
- [13] Charles R. Harris y col. «Array programming with NumPy». En: *Nature* 585.7825 (2020), págs. 357-362. DOI: 10.1038/s41586-020-2649-2.
- [14] Alexander Kirillov y col. «Segment Anything». En: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, págs. 4015-4026. DOI: 10.1109/ICCV51070.2023.00371.
- [15] Haiqiang Liu y col. «A hybrid attention semantic segmentation network for unstructured terrain on Mars». En: *Acta Astronautica* 204 (2023), págs. 492-499. DOI: 10.1016/j.actaastro.2022.08.002.
- [16] Ralph D. Lorenz. «Analytic rock abundance distributions and their application to spacecraft landing hazards». En: *Planetary and Space Science* 234 (2023), pág. 105720. DOI: 10.1016/j.pss.2023.105720.
- [17] Yuchen Ma y col. «DepthFormer: Depth-enhanced transformer network for semantic segmentation of the Martian surface from rover images». En: *Earth and Space Science* 12.6 (2025), e2024EA003812. DOI: 10.1029/2024EA003812.

- [18] NASA Jet Propulsion Laboratory. *Planetary Data System — Imaging Node*. <https://pds-imaging.jpl.nasa.gov/>. 2024.
- [19] NASA Jet Propulsion Laboratory. *Premature Wear of the MSL Wheels*. <https://llis.nasa.gov/lesson/22401>. 2017.
- [20] Yang Qu y col. «A systematic review of Martian image segmentation techniques for Mars exploration (from 2019 to 2025)». En: *Advances in Space Research* (2025). doi: 10.1016/j.asr.2025.08.042.
- [21] Brandon Rothrock y col. «SPOC: Deep learning-based terrain classification for Mars rover missions». En: *AIAA SPACE 2016*. 2016. doi: 10.2514/6.2016-5539.
- [22] Reza Sharifi, Ali Ghorbani y Ahmet H. Deliormanli. «Determining rock fragment size distribution using a convolutional neural network». En: *Rudarsko-geološko-naftni zbornik* (2024). doi: 10.17794/rgn.2024.2.1.
- [23] Xiaohui Sun y col. «The characteristic and size–frequency distribution of rocks at the Zhurong landing site, Mars». En: *Frontiers in Astronomy and Space Sciences* 11 (2024), pág. 1270079. doi: 10.3389/fspas.2024.1270079.
- [24] R. Michael Swan, Masahiro Ono y Deegan Atha. *AI4Mars: A Dataset for Terrain-Aware Autonomous Driving on Mars*. Ver. 0.6. 2022. doi: 10.5281/zenodo.15995036.
- [25] R. Michael Swan y col. «AI4MARS: A Dataset for Terrain-Aware Autonomous Driving on Mars». En: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*. 2021, págs. 1982-1991. doi: 10.1109/CVPRW53098.2021.00226.
- [26] Peng Tian y Meibao Yao. «RSU-Net: An attention U-Net for Martian rock segmentation». En: *Journal of Physics: Conference Series* 2762.1 (2024), pág. 012001. doi: 10.1088/1742-6596/2762/1/012001.

- [27] Luc Vincent y Pierre Soille. «Watersheds in digital spaces: An efficient algorithm based on immersion simulations». En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 13.6 (1991), págs. 583-598. DOI: 10.1109/34.87344.
- [28] Pauli Virtanen y col. «SciPy 1.0: Fundamental algorithms for scientific computing in Python». En: *Nature Methods* 17.3 (2020), págs. 261-272. DOI: 10.1038/s41592-019-0686-2.
- [29] Stéfan van der Walt y col. «scikit-image: Image processing in Python». En: *PeerJ* 2 (2014), e453. DOI: 10.7717/peerj.453.
- [30] Chuanjin Wang y col. «GMSRI: A texture-based Martian surface rock image dataset». En: *Sensors* 21.16 (2021), págs. 5410. DOI: 10.3390/s21165410.
- [31] Ryan N. Watkins y col. «Boulder distributions around young, small lunar impact craters». En: *Journal of Geophysical Research: Planets* 124.10 (2019), págs. 2754-2771. DOI: 10.1029/2019JE005963.
- [32] Yiqing Xiong y col. «MarsFormer: Martian rock semantic segmentation with transformer». En: *IEEE Transactions on Geoscience and Remote Sensing* 61 (2023), págs. 1-12. DOI: 10.1109/TGRS.2023.3302371.
- [33] Xu Zhao y col. «Fast Segment Anything». En: *arXiv preprint arXiv:2306.12156* (2023). DOI: 10.48550/arXiv.2306.12156.